MÁY HỌC

THUẬT TOÁN
AFFINITY PROPAGATION

GVHD: TS. Nguyễn An Tế

Nhóm 7

Kim Phan Thúy Liễu

Vương Thùy Linh

Trịnh Thảo Minh

Nguyễn Đỗ Nhật Minh

Trần Khánh Ngân

MỤC TIÊU

Nghiên cứu cách hoạt động thuật toán Affinity Propagation

Ứng dụng thuật toán Affinity Propagation

Sử dụng bộ dữ liệu Customer Personality Analysis để minh họa

Đánh giá hiệu suất & so sánh với các thuật toán phân cụm khác

THUẬT TOÁN AP

"Affinity Propagation mô phỏng quy trình 'bỏ phiếu' dân chủ, nơi mỗi điểm dữ liệu ảnh hưởng và bị ảnh hưởng bởi các điểm khác để tìm ra cấu trúc cụm tự nhiên nhất."

— Brendan J. Frey & Delbert Dueck, Science 2007

Định nghĩa & Lịch sử

Thuật toán phân cụm dựa trên việc **truyền thông điệp** giữa các điểm dữ liệu. Không yêu cầu số lượng cụm được xác định trước.

Cơ chế

- Xác định các 'exemplar' (điểm đại diện) từ chính dữ liệu.
- Các điểm dữ liệu khác tự động gán vào exemplar gần nhất.
- Trao đổi 'responsibilities' và 'availabilities' lặp lại.

Ưu điểm nổi bật

- Tự động xác định số lượng cụm tối ưu.
- Exemplar là các điểm dữ liệu thực tế, dễ diễn giải.
- Hiệu quả cho dữ liệu phức tạp, mật độ cao.
- Không cần tham số khởi tạo ngẫu nhiên như K-Means.

ỨNG DỤNG

Nhận dạng khuôn mặt

Phân cụm khuôn mặt tương tự trong cơ sở dữ liệu lớn để nhận dạng và theo dõi hiệu quả.

Computer Vision

Phân tích hành vi người dùng

Nhóm người dùng có hành vi tương đồng để cá nhân hóa trải nghiệm và đề xuất sản phẩm.

Marketing Analytics

Xử lý ngôn ngữ tự nhiên (NLP)

Phân loại tài liệu, tóm tắt văn bản và phát hiện chủ đề trong khối lượng dữ liệu văn bản lớn.

Text Mining

Sinh học và mạng xã hội

Phân tích mạng lưới gen, protein và cấu trúc mạng xã hội để phát hiện cộng đồng.

Network Analysis

CÁC THÀNH PHẦN CHÍNH

Ma trận tương đồng S (Similarity Matrix)

Đo lường mức độ tương đồng giữa các cặp điểm dữ liệu.

Là nền tảng cho tương tác ban đầu.

Exemplars (Điểm mẫu)

Các điểm dữ liệu được chọn làm đại diện cho một cụm.

Tự động chọn thông qua quá trình truyền tin.

Thông điệp Responsibility (Trách nhiệm)

Mức độ điểm xj phù hợp làm exemplar cho điểm xi.

Cập nhật dựa trên ma trận tương đồng S và Availability.

Thông điệp Availability (Sẵn sàng)

Mức độ điểm xi chấp nhận cho xj làm exemplar cho chính nó.

Cập nhật dựa trên responsibility của xj.

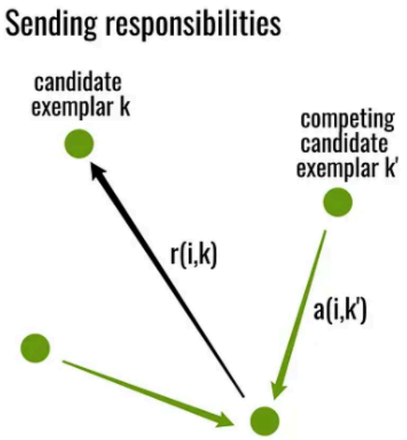

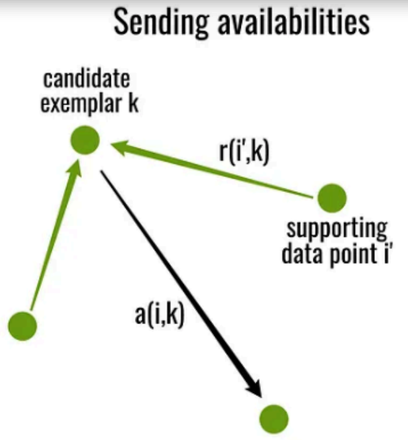

CƠ CHẾ CẬP NHẬT

Bước 1: Khởi tạo ma trận S và preference

- Mỗi phần tử s(i,k) trong ma trận S đại diện cho độ tương đồng giữa xi và xk.
- Công thức tính mặc định:

$$s(i,k) = -\left|\left|x_i - x_k\right|\right|^2$$

$$S = \begin{bmatrix} 0.0 & 0.5 & 0.2 \\ 0.5 & 0.0 & 0.4 \\ 0.2 & 0.4 & 0.0 \end{bmatrix}$$

Preference = 0

- Các điểm trên đường chéo chính được gọi là preference, thể hiện cho mức độ tự tin bản thân có thể làm exemplar.
- Preference càng thấp => số cụm càng giảm

CƠ CHẾ CẬP NHẬT LẦN LẶP 1

Bước 2: Tính toán ma trận R

- Mỗi phần tử r(i,k) trong ma trận R đại diện cho điểm đánh giá k phù hợp làm exemplar cho i.
- Công thức tính:

$$r(i,k) = s(i,k) - \max_{k' \neq k}\left(a(i,k') + s(i,k')\right)$$

- r(i,k) càng cao => k càng phù hợp làm exemplar hơn so với các ứng cử viên khác.

VD:

s(1,1) = 0.0

s(1,2) = 0.5

s(1,3) = 0.2

=> r(1,1) = **s(1,1)** - max(**s(1,2)**, **s(1,3)**) = -0.5

$$R = \begin{bmatrix} -0.5 & 0.3 & -0.3 \\ 0.1 & -0.5 & -0.1 \\ -0.2 & 0.2 & -0.4 \end{bmatrix}$$

CƠ CHẾ CẬP NHẬT LẦN LẶP 1

Bước 3: Tính toán ma trận A

- Mỗi phần tử a(i,k) thể hiện cho sự công nhận từ i, tức i chấp nhận k là exemplar.
- Công thức tính:

$$a(i,k) = \min\left(0, r(k,k) + \sum_{i' \in \{i,k\}} \max(0, r(i',k))\right)$$

$$a(k,k) = \sum_{i' \neq k} \max(0, r(i',k))$$

VD:

Điểm trên đường chéo:

a(1,1) = max(0, **r(2,1)**) + max(0, **r(3,1)**) = 0.1

Điểm ngoài đường chéo:

a(2,1) = min (0, **r(1,1)** + (max(0, **r(1,1)**) + max(0, **r(3,1)**))) = -0.5

$$A = \begin{bmatrix} 0.1 & -0.3 & -0.4 \\ -0.5 & 0.5 & -0.4 \\ -0.4 & -0.2 & 0.0 \end{bmatrix}$$

CƠ CHẾ CẬP NHẬT LẦN LẶP 1

Bước 4: Tính toán ma trận E

- Ma trận E là tổng của hai ma trận R và A
- Sau khi tính được ma trận E, xét đường chéo chính để tìm các điểm tiềm năng trở thành exemplar:

  e(i,i) = r(i,i) + a(i,i) > 0

$$E = R + A = \begin{bmatrix} -0.4 & 0.0 & -0.7 \\ -0.4 & 0.0 & -0.5 \\ -0.6 & 0.0 & -0.4 \end{bmatrix}$$

Không có e(i,i) nào thỏa điều kiện lớn hơn 0

=> Chưa có điểm exemplar

CƠ CHẾ CẬP NHẬT

LẦN LẶP 2

damping nằm trong khoảng [0.5 - 1.0]

$$R_{\text{updated}} = \text{damping} \times R_{\text{old}} + (1 - \text{damping}) \times R_{\text{new}}$$

$$A_{\text{updated}} = \text{damping} \times A_{\text{old}} + (1 - \text{damping}) \times A_{\text{new}}$$

Chỉ số damping càng lớn → thời gian chạy lâu hơn nhưng thuật toán hội tụ ổn định hơn → số cụm chính xác hơn.

Lặp lại từ bước 2 đến bước 4

- Tính toán theo công thức tương tự ở lần lặp đầu tiên.
- Riêng ở bước 2 - tính toán ma trận R, và bước 3 - tính toán ma trận A: sau khi tính toán xong phải sử dụng thêm hệ số damping
- Mục đích của damping: để đảm bảo làm mượt quá trình cập nhật messages giữa các điểm dữ liệu, tránh dao động (oscillation).

CƠ CHẾ CẬP NHẬT

```
========================================
KẾT QUẢ CUỐI CÙNG
========================================
Số exemplars: 1
Các exemplars: ['B']

Phân cụm ĐÚNG:
  A → B
  B → B
  C → B

Ma trận E (R + A):
       A      B      C
A -0.382  0.365 -0.576
B -0.388  0.463 -0.428
C -0.513  0.353 -0.363

Đường chéo của E (quyết định exemplar):
  A: -0.382
  B: 0.463 (EXEMPLAR)
  C: -0.363
```

Hội tụ

- Khi tập hợp các điểm exemplars không thay đổi sau n lần lặp liên tục, thuật toán sẽ kết thúc và trả ra kết quả: các exemplars dùng để xác định các clusters.
- Điều chỉnh số lần lặp dựa trên tham số convergence_iter tùy thuộc vào mục tiêu sử dụng.

BỘ DỮ LIỆU

- **Tên bộ dữ liệu:** Customer Personality Analysis - Kaggle
- **Mục tiêu:** Hỗ trợ doanh nghiệp phân tích hành vi và đặc điểm khách hàng để tối ưu chiến lược marketing, phân khúc khách hàng.
- **Số lượng bản ghi:** Hơn 2.200 khách hàng.
- **Số lượng thuộc tính:** 29 thuộc tính mô tả thông tin nhân khẩu học, thu nhập, hành vi mua hàng, và mức độ tương tác với chiến dịch marketing.

XỬ LÝ GIÁ TRỊ THIẾU

- Thuộc tính **Income** có **24** giá trị thiếu trên 2.240 bản ghi **(tỉ lệ 1,07%).**
- Phân phối Income tập trung quanh trung vị ~50.000, chỉ có ít giá trị ngoại lai (outliers).
- Xử lý: Điền các giá trị thiếu của Income **bằng trung vị** để đảm bảo tính ổn định và tránh bị ảnh hưởng bởi outliers.

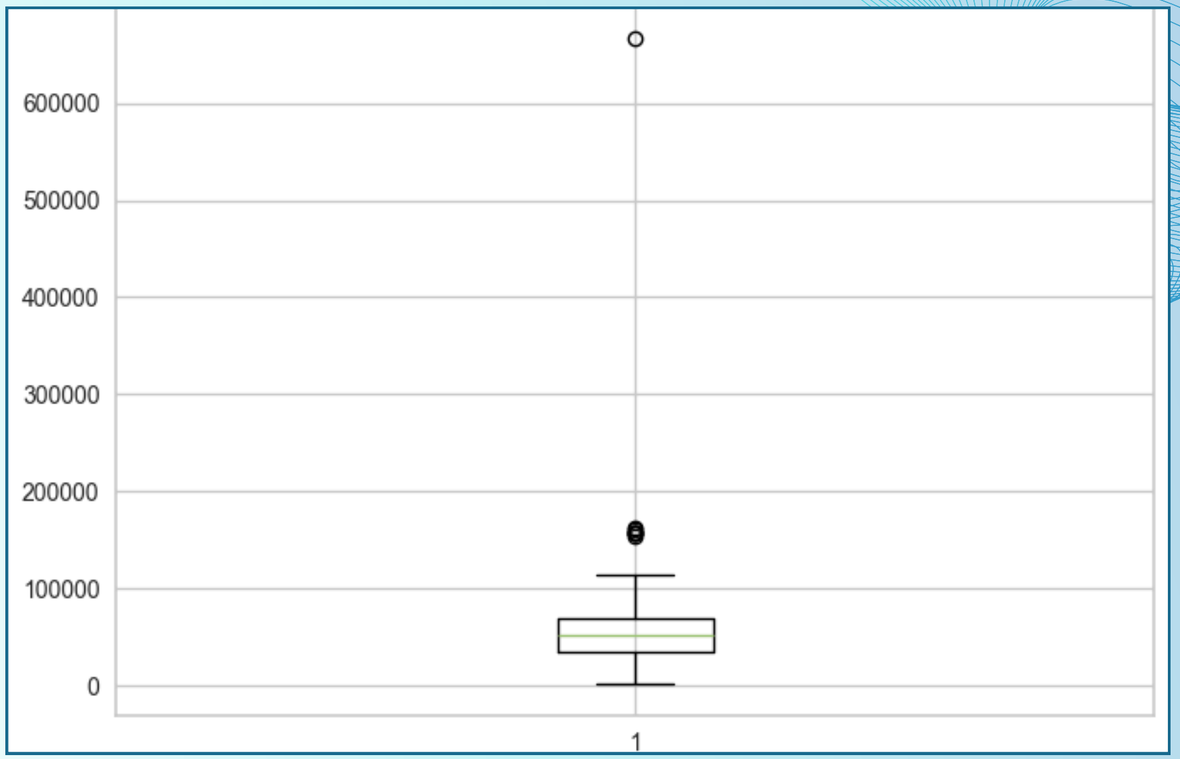

XỬ LÝ GIÁ TRỊ NGOẠI LAI

- Tính tuổi khách hàng: **Age** = 2025 - Year_Birth.
- Dùng Boxplot để biểu diễn và phát hiện outliers.
- **Loại bỏ giá trị tuổi > 90** vì không hợp lý và ít ý nghĩa phân tích.

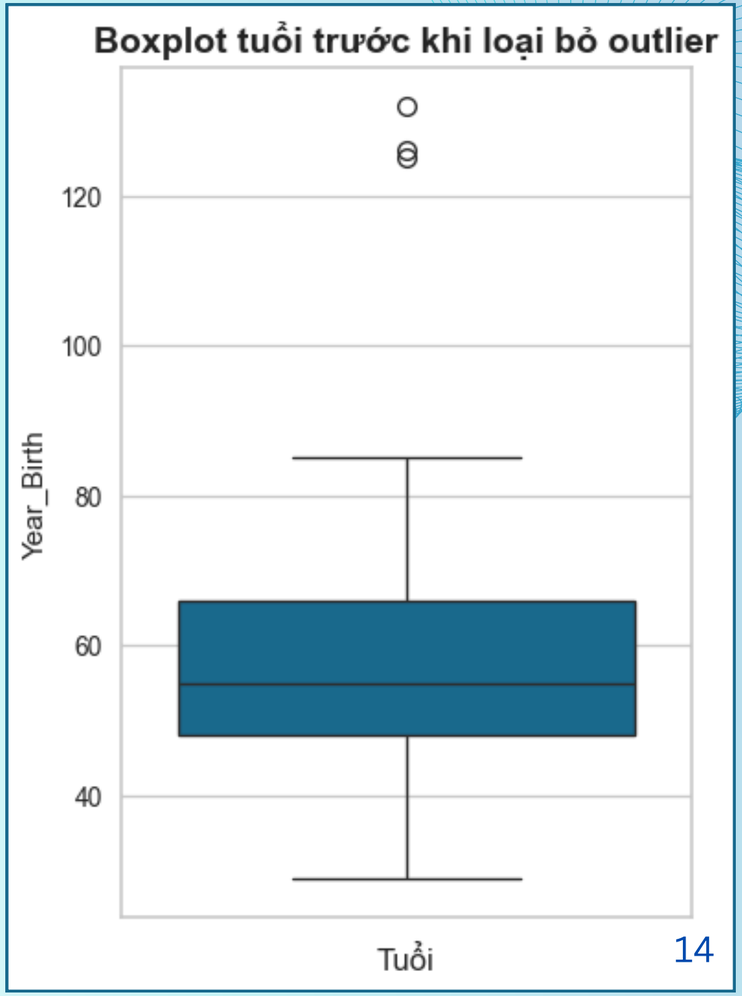

XỬ LÝ GIÁ TRỊ NGOẠI LAI

- **Biến xử lý: Marital_Status** – tình trạng hôn nhân.

- **Kết quả thống kê:** Có các giá trị đặc biệt Alone và YOLO → gộp vào nhóm Single (độc thân).

- **Xử lý ngoại lệ:** Giá trị Absurd không có ý nghĩa, chỉ xuất hiện 2 bản ghi → tiến hành loại bỏ.

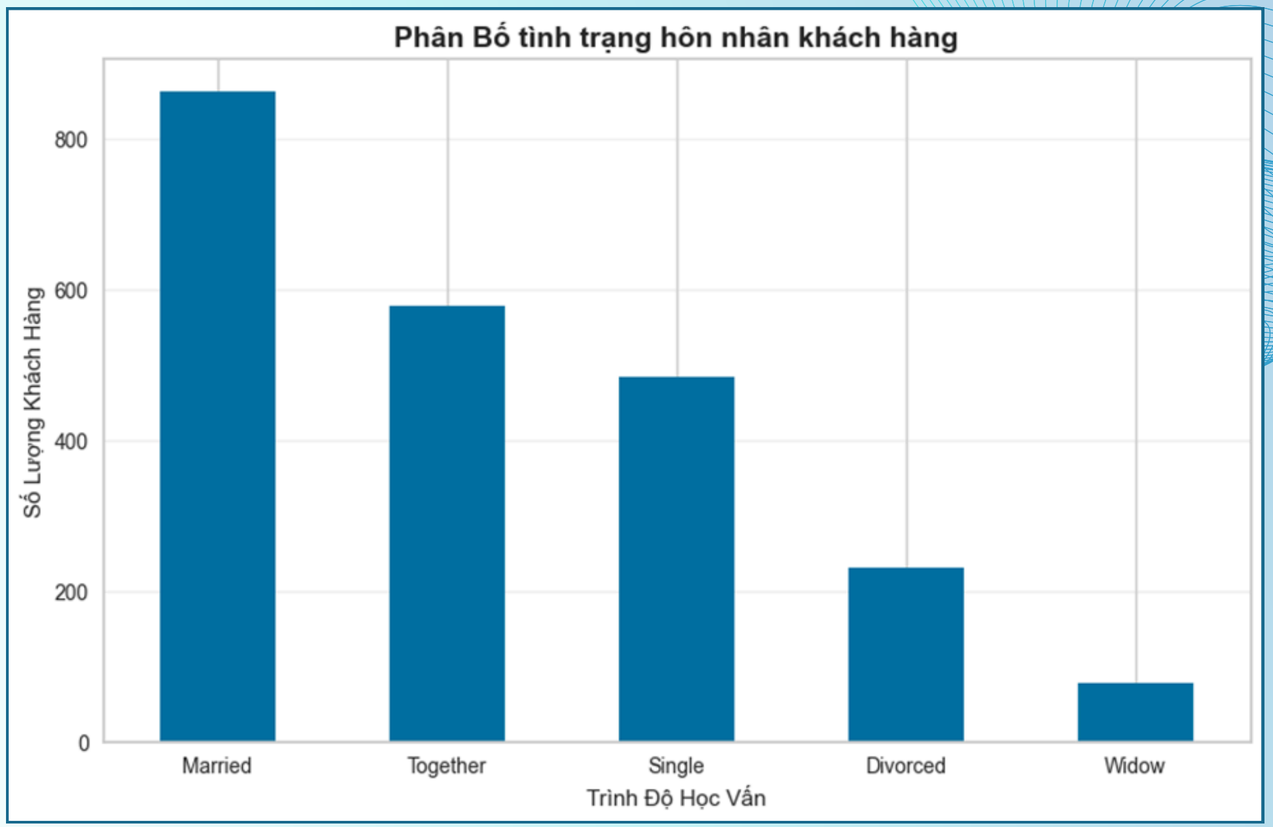

XỬ LÝ GIÁ TRỊ NGOẠI LAI

- **Biến xử lý: Income** – thu nhập khách hàng.
- **Quan sát Boxplot:** Phần lớn thu nhập < 100.000, một số khách hàng có thu nhập cao đến 200.000 vẫn hợp lý.
- **Ngoại lệ:** Một giá trị ~650.000 → loại bỏ.

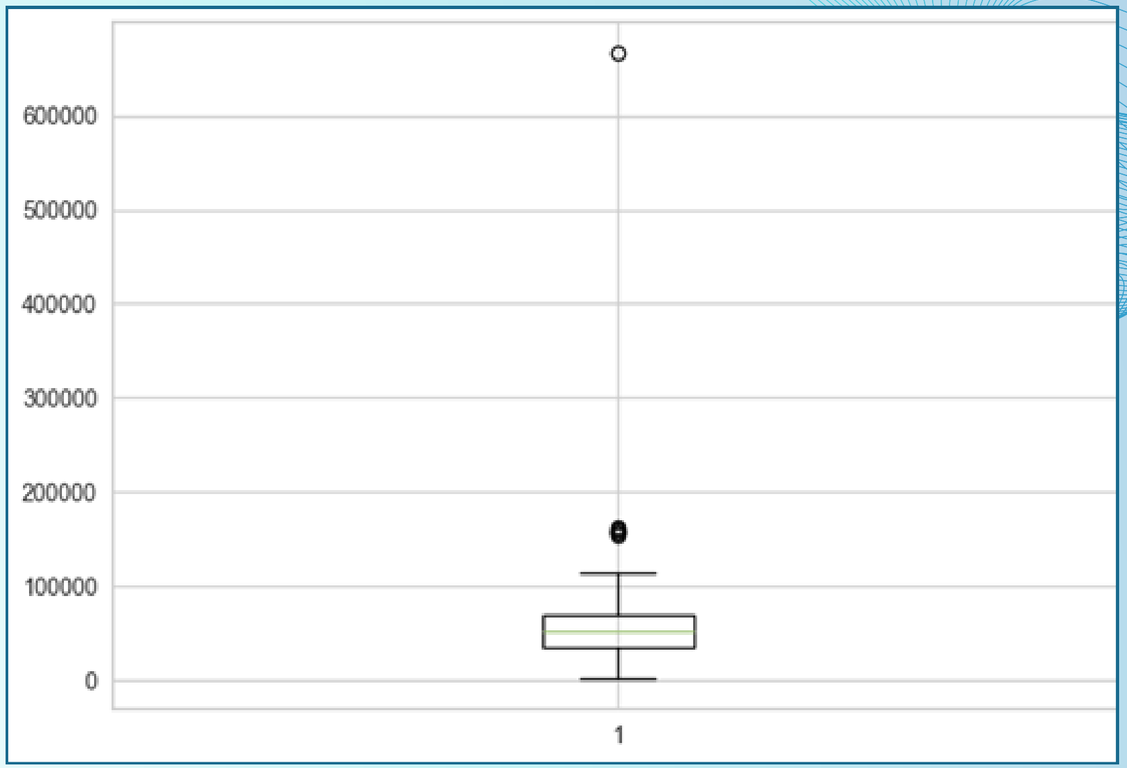

CHUYỂN DẠNG DỮ LIỆU

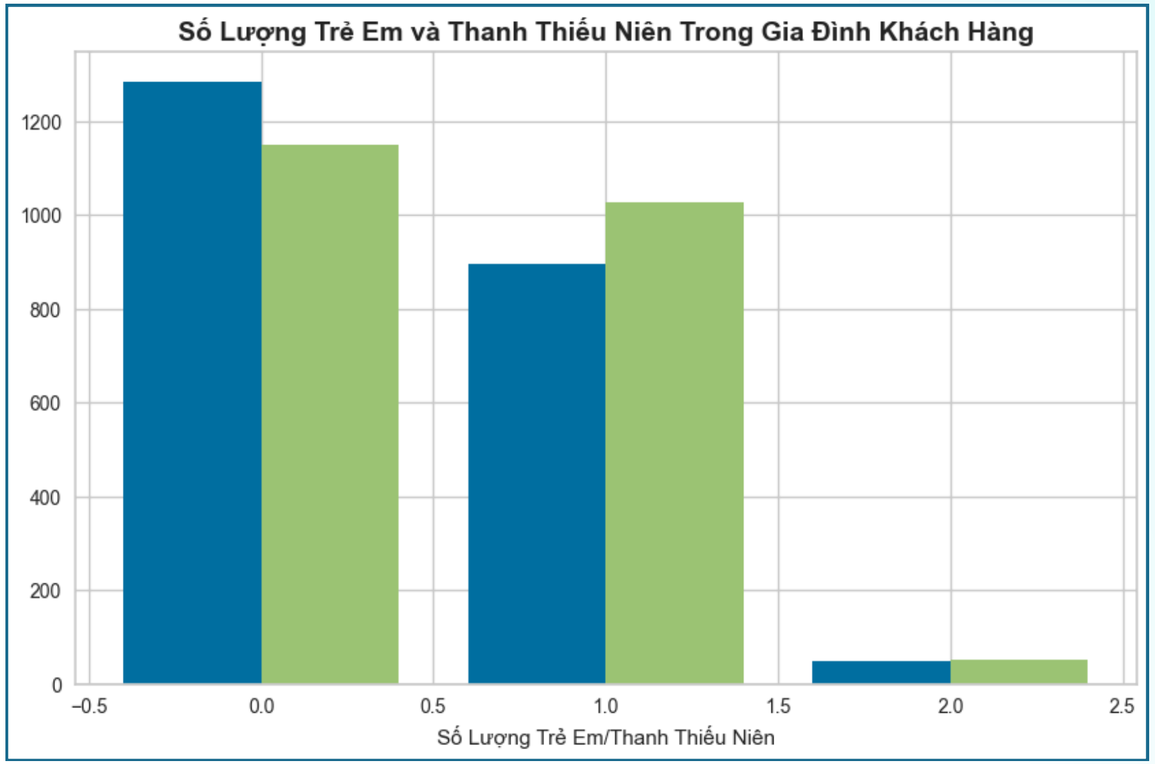

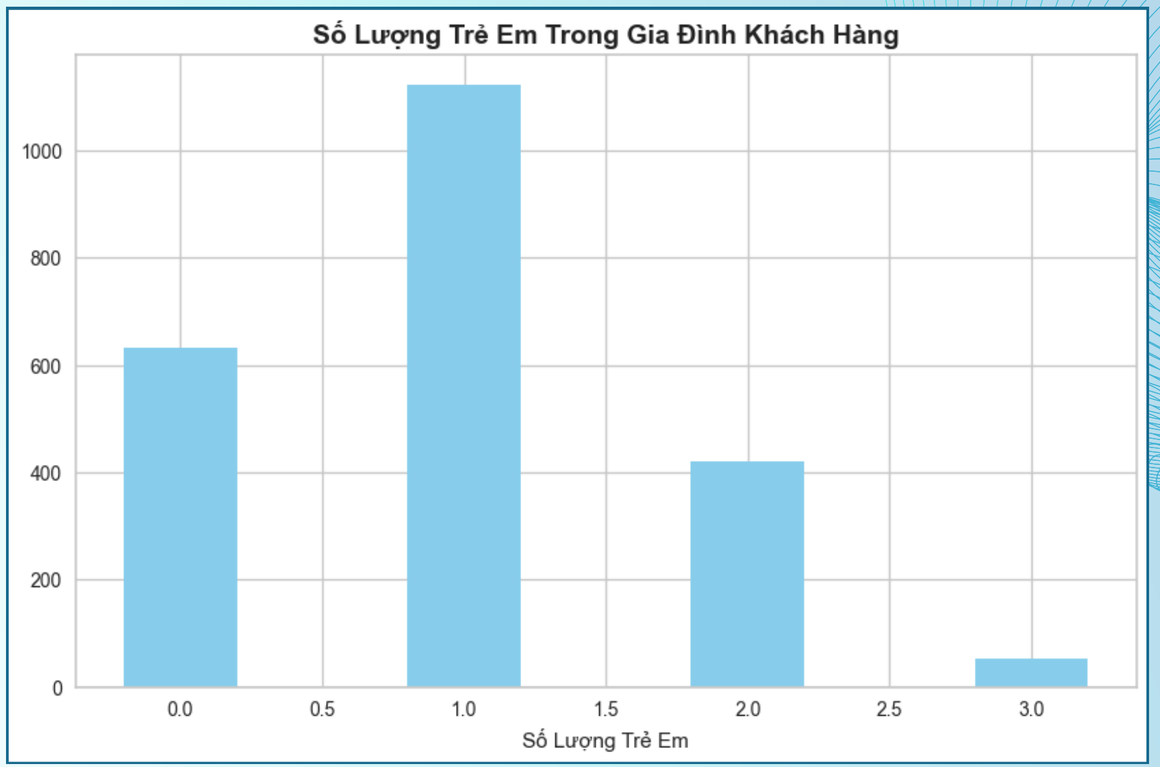

- Số lượng trẻ em và thiếu niên được thống kê khá tương đồng
- Gom 2 biến trên thành 1 biến là **số lượng con trong gia đình**

CHUYỂN DẠNG DỮ LIỆU

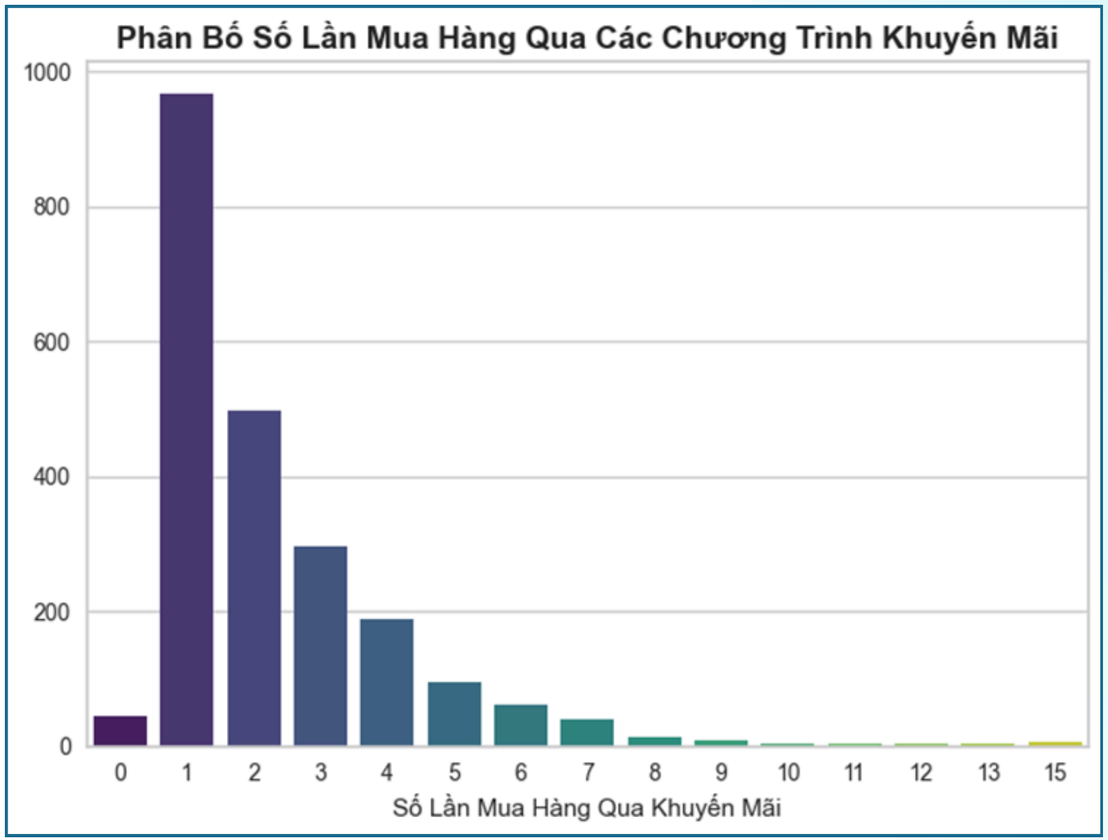

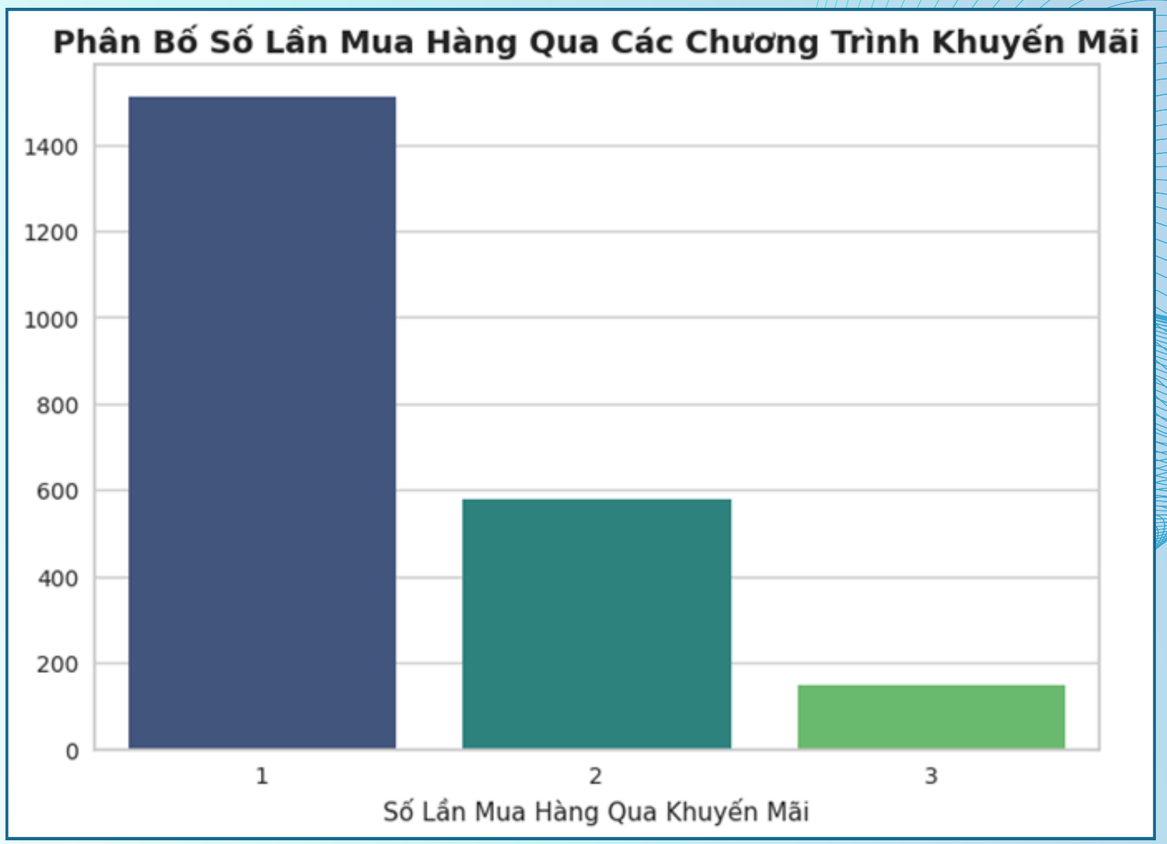

- Biến xử lý: NumDealsPurchases – số đơn hàng mua giảm giá.
- Quan sát: Các giá trị từ 9–15 xuất hiện rất ít, gây mất cân bằng dữ liệu.
- Gom nhóm Mua ít: 0–2, Mua vừa: 3–5, Mua nhiều: >5

MỘT SỐ PHÂN PHỐI KHÁC

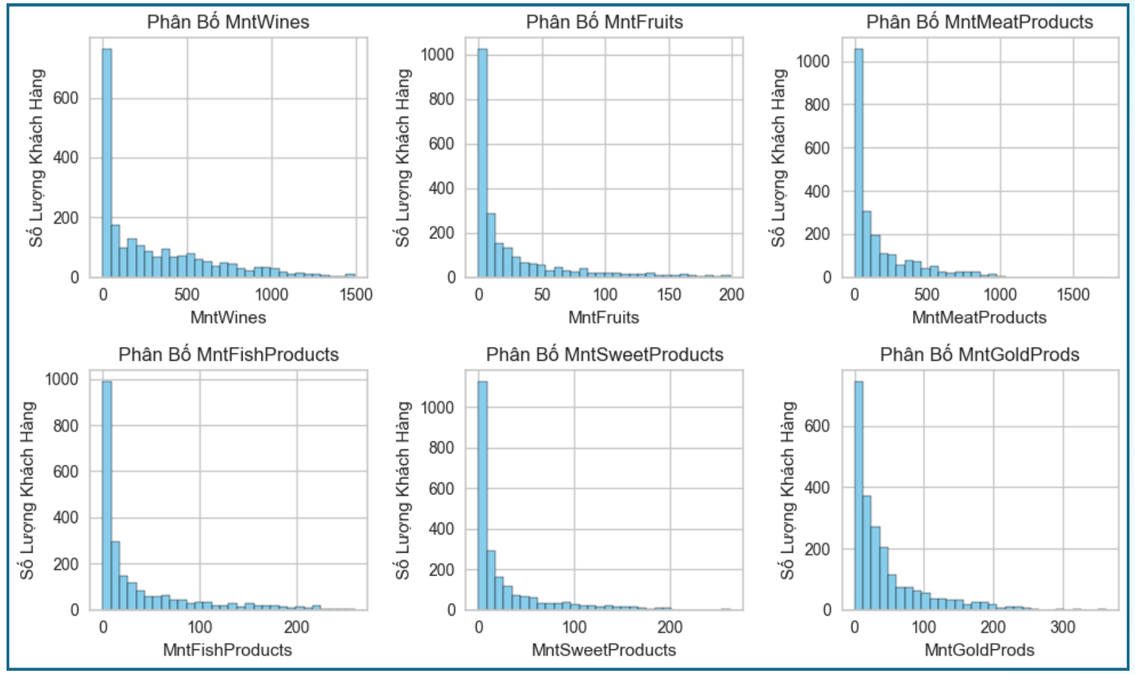

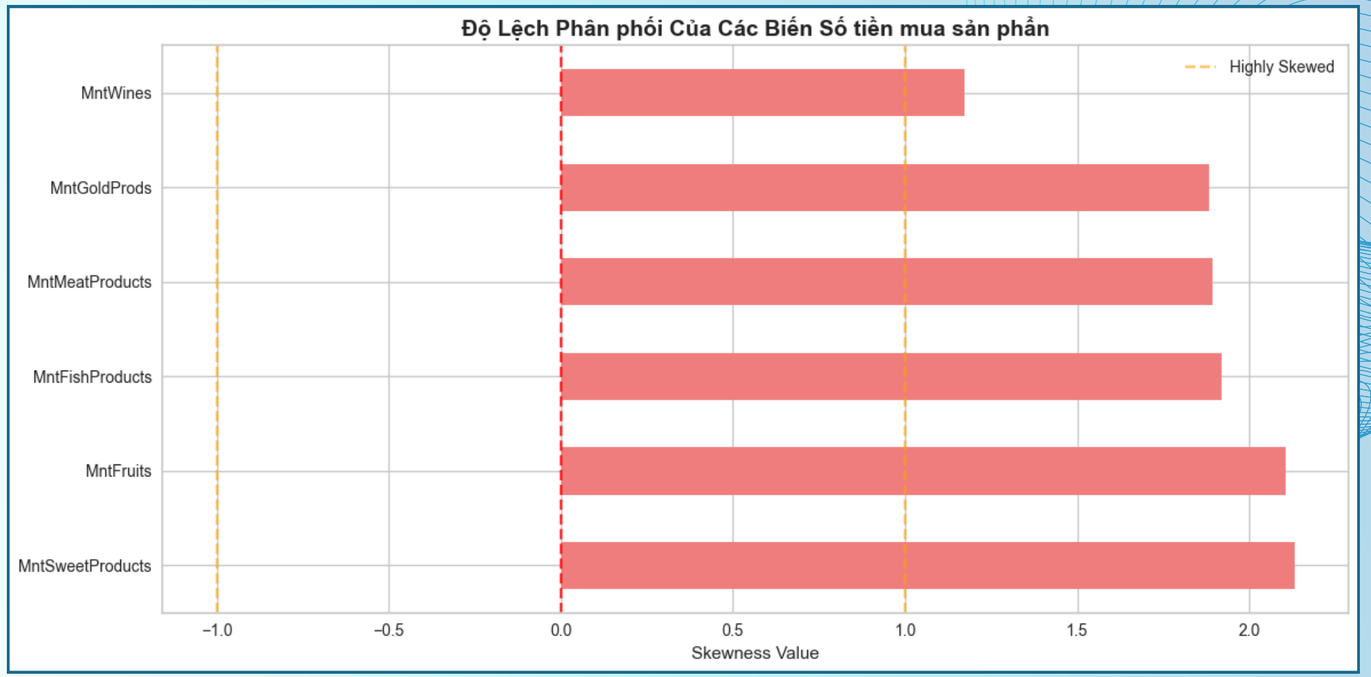

- Phản ánh đúng hành vi mua sắm của khách hàng đa dạng và khó đoán
- Để giữ được cấu trúc tự nhiên của dữ liệu → ta không xử lí các biến này.

MỘT SỐ PHÂN PHỐI KHÁC

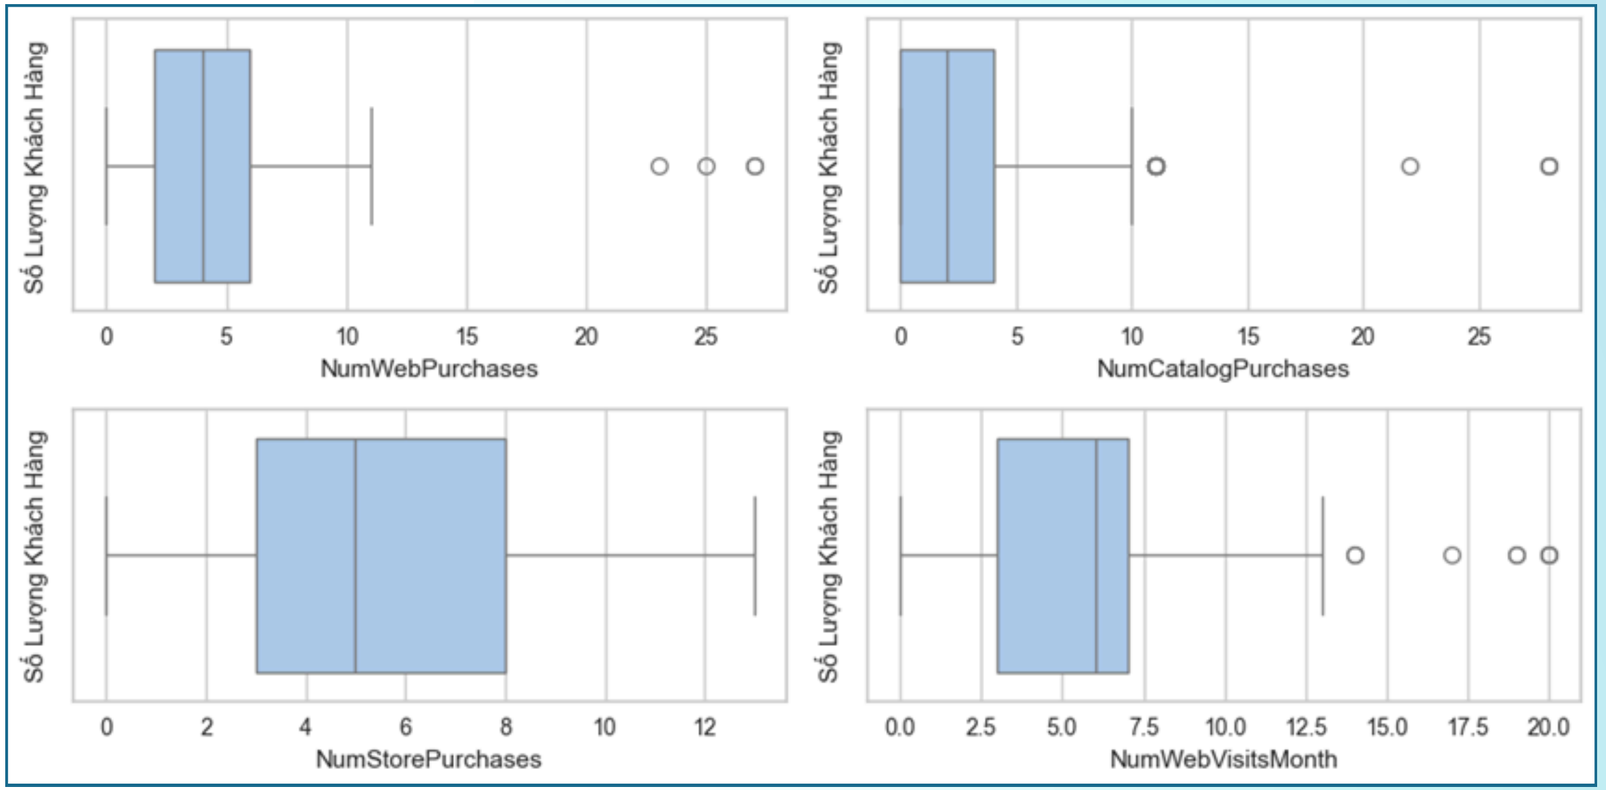

- Nhóm Place cho biết số lượt mua của khách hàng thông qua 3 kênh và số lượng truy cập web mỗi tháng của khách hàng
- Có outliers nhưng so với thang đo trong mỗi biến và ý nghĩa thực tế, các giá trị này là hoàn toàn có thể xảy ra

MỘT SỐ PHÂN PHỐI KHÁC

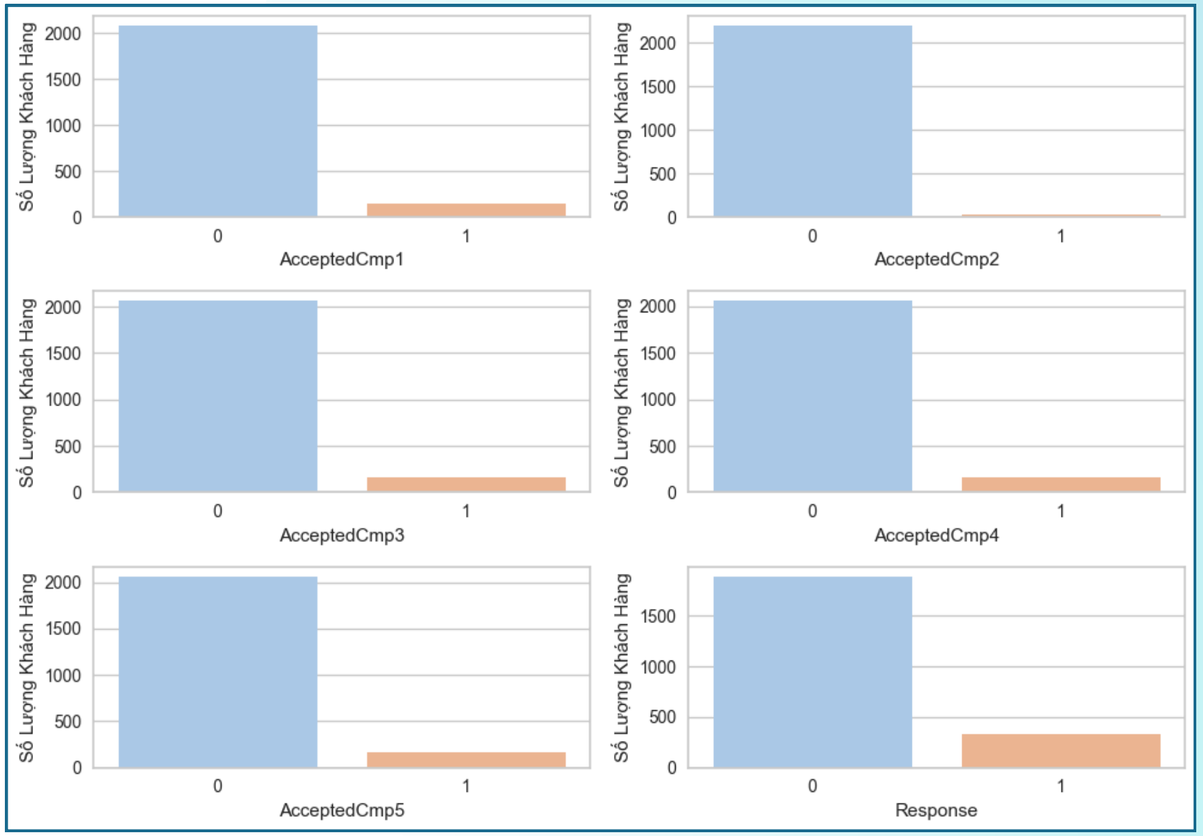

- Số lượng khách hàng chấp nhận chiến dịch quảng cáo thấp hơn rất nhiều so với số lượng không chấp nhận → loại bỏ các thuộc tính này

GIẢM CHIỀU DỮ LIỆU

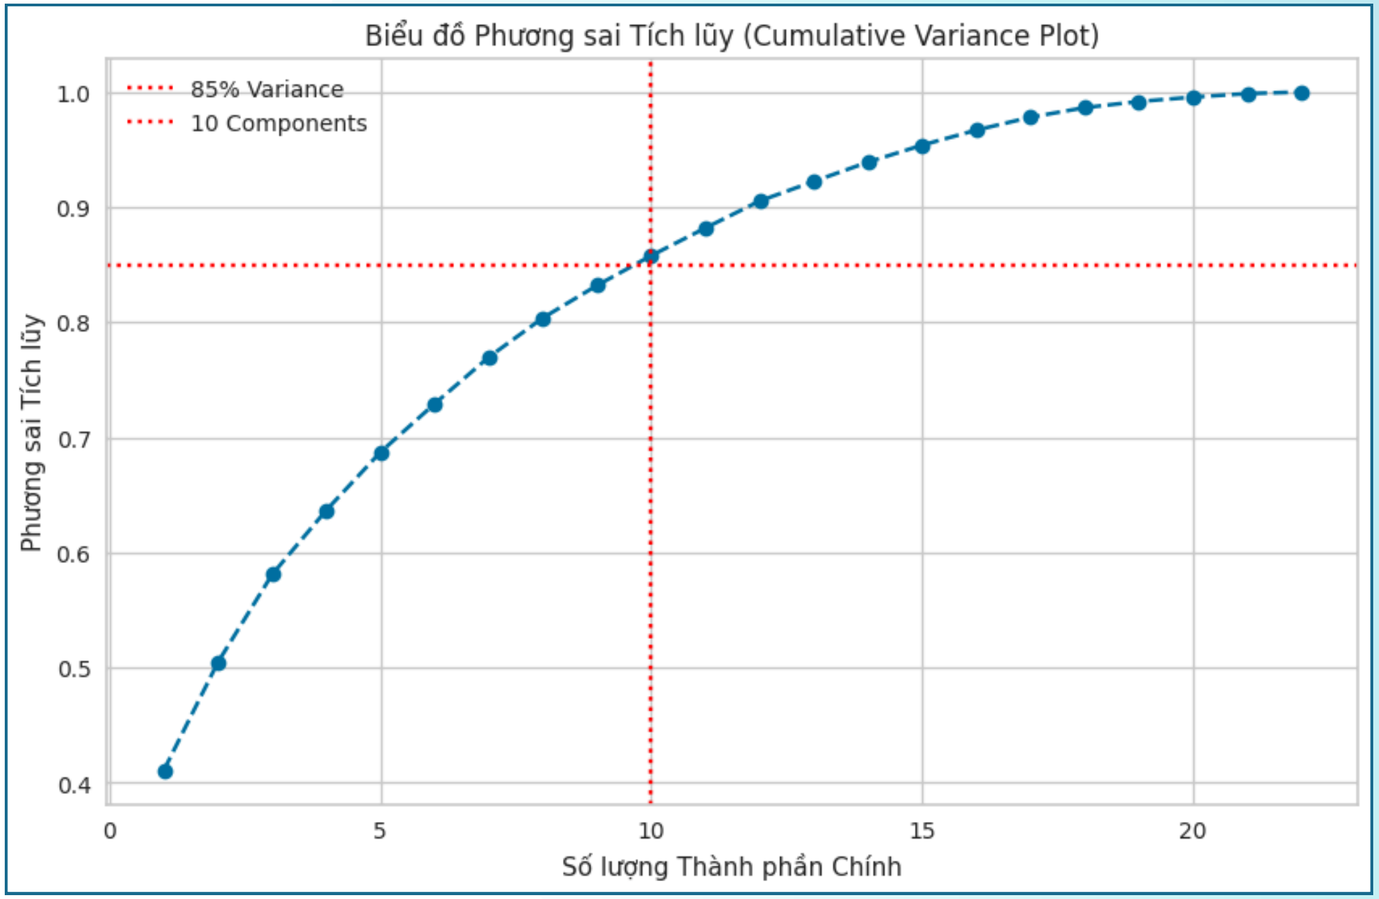

- Giữ lại 10 thành phần chính nhằm bảo toàn phần lớn thông tin của tập dữ liệu
- Đồng thời, giảm chi phí tính toán trong các bước phân cụm tiếp theo.

ÁP DỤNG VÀ ĐÁNH GIÁ GIẢI THUẬT

Tham số	Vai trò	Giá trị thường dùng	Ảnh hưởng đến kết quả
preference	Mức độ ưu tiên để điểm trở thành exemplar	Gần median/mean của similarity, hoặc thử nhiều giá trị	Quyết định **số cụm** (cao → nhiều cụm, thấp → ít cụm)
damping	Giảm dao động khi cập nhật thông điệp	0.7 → 0.95	Cao → ổn định chậm hơn, thấp → dễ không hội tụ
max_iter	Số vòng lặp tối đa để cập nhật messages	200 → 1000	Quá thấp → chưa kịp hội tụ
convergence_iter	Số vòng lặp liên tiếp không đổi để coi hội tụ	15 → 50	Thấp quá → tưởng hội tụ sớm, kết quả kém ổn định
affinity	Cách tính similarity	'euclidean' hoặc 'precomputed'	Ảnh hưởng trực tiếp chất lượng cụm nếu dữ liệu đặc thù

TINH CHỈNH THAM SỐ

Tham số **preference** sẽ được xác định bằng cách đưa vào vòng lặp, thử áp dụng preference trong giá trị từ (-4000,0) với bước nhảy là 200 để chọn ra preference tối ưu nhất dựa vào ba chỉ số đánh giá như hình bên.

Từ kết quả thu được, nhóm quyết định chọn **preference = -1800** để đưa vào mô hình huấn luyện.

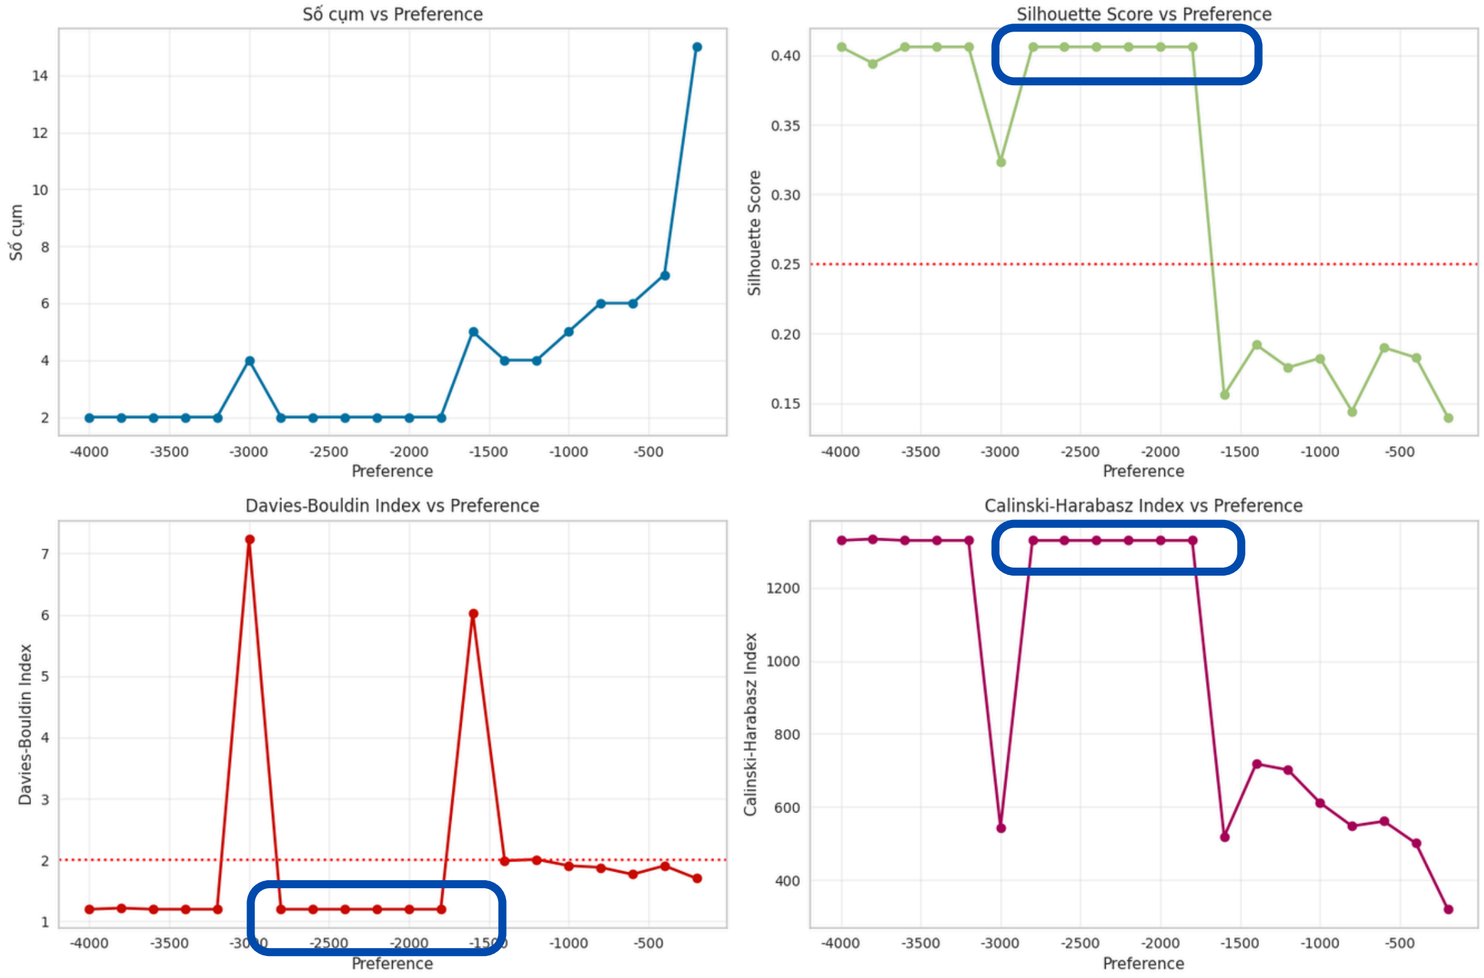

Hình: Tổng hợp các kết quả từ ba chỉ số đánh giá: Silhouette, Davies–Bouldin, và Calinski–Harabasz

KẾT QUẢ PHÂN CỤM

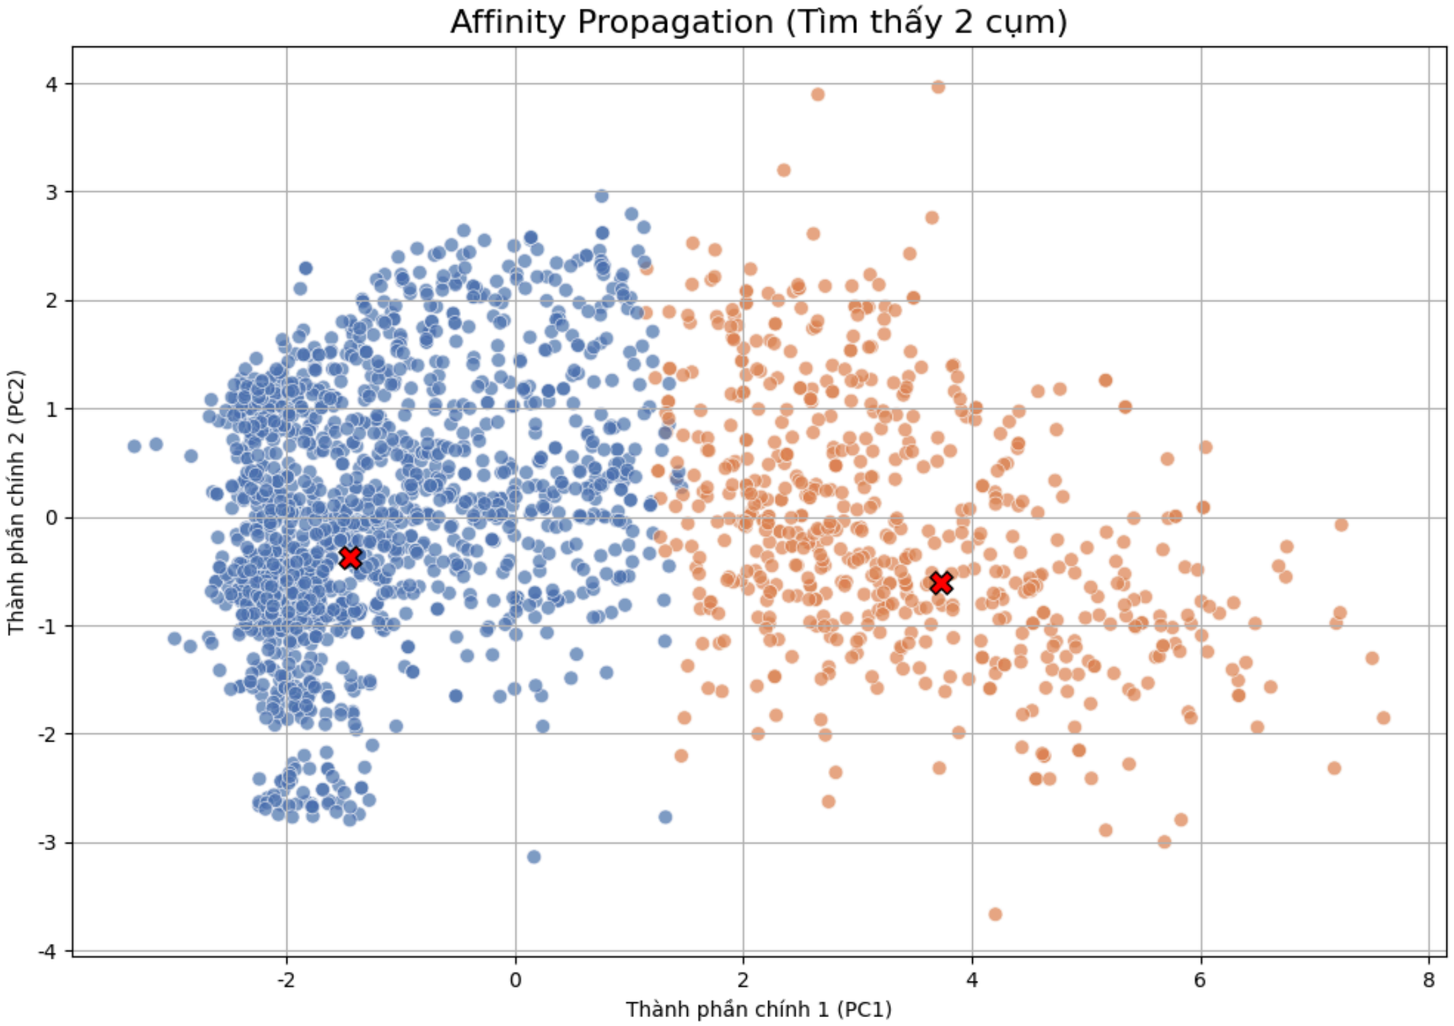

Hình: Kết quả phân cụm của thuật toán AP với preference = -1800

Silhoutte Score: 0.4060

Nhận xét:

- **Có 2 cụm**: Cụm 0 (vàng), và Cụm 1 (xanh).
- Các cụm này **phân tách rõ ràng.**

SO SÁNH

Phân cụm KMeans

Phương pháp ELBOW

Giá trị tối ưu cho k = 2

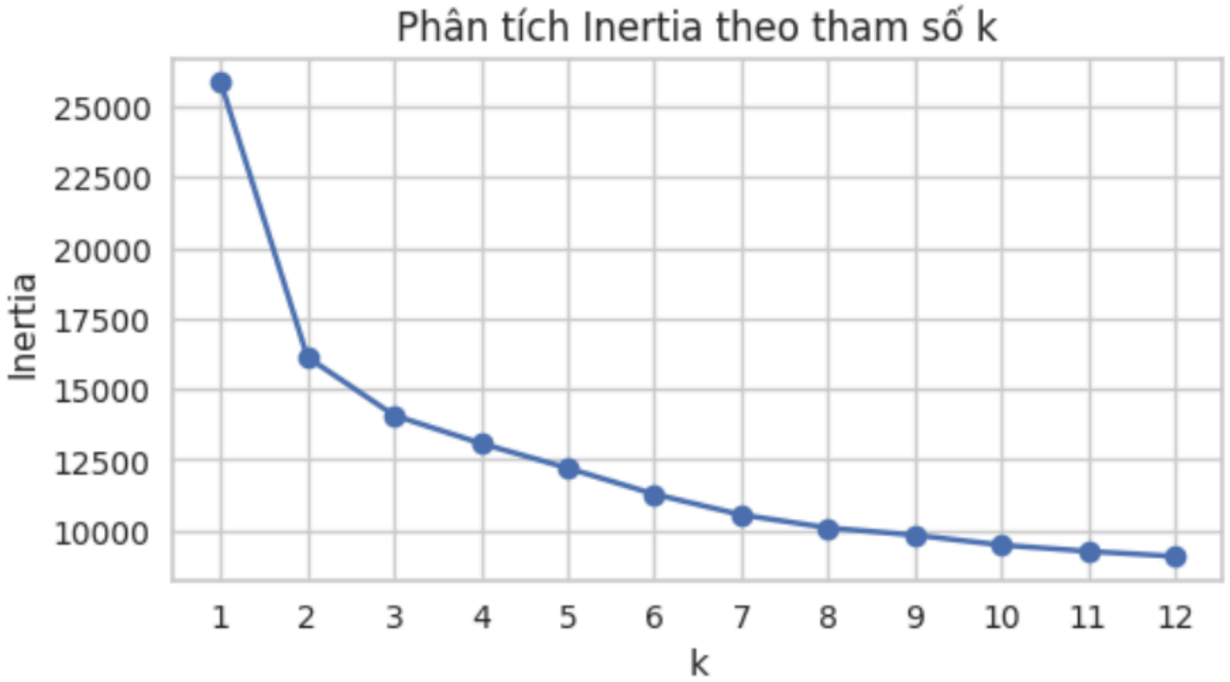

Phương pháp SILHOUETTE SCORE

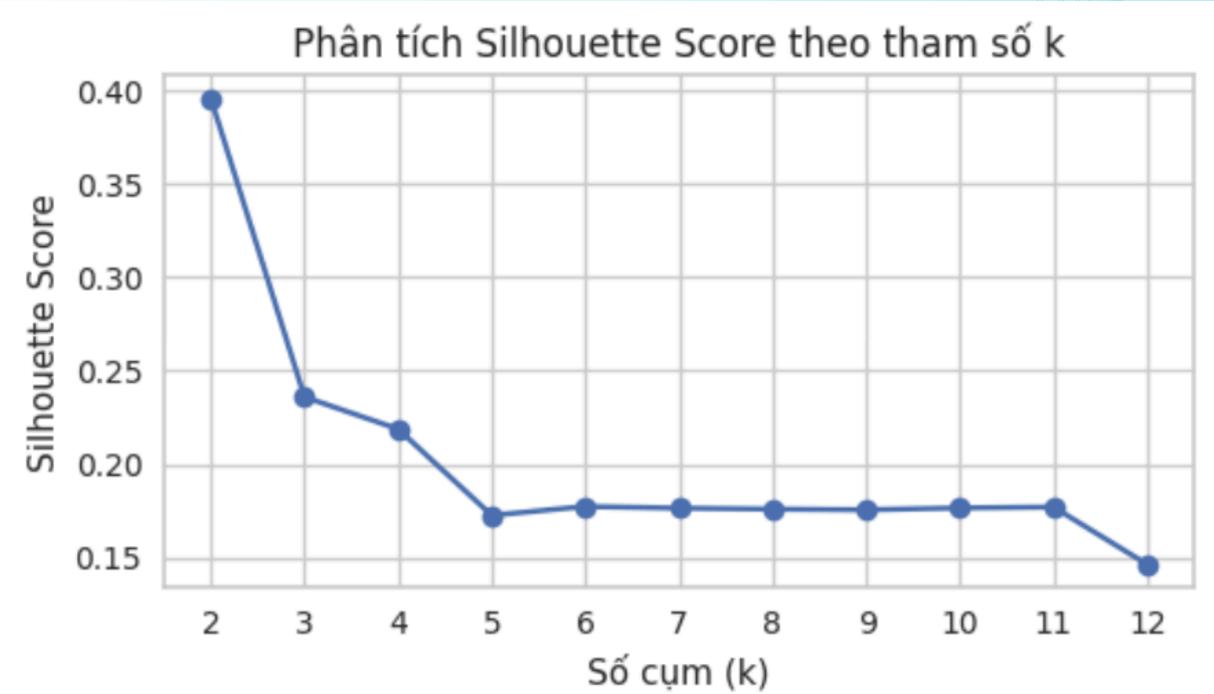


```
Giá trị tối ưu cho k: 2
```

SO SÁNH

Phân cụm KMeans

Phương pháp ELBOW

- Kết quả: 2 cụm
- Một số điểm gần ranh giới giữa hai cụm phân loại chưa rõ ràng => Ranh giới giữa các cụm giao thoa nhẹ

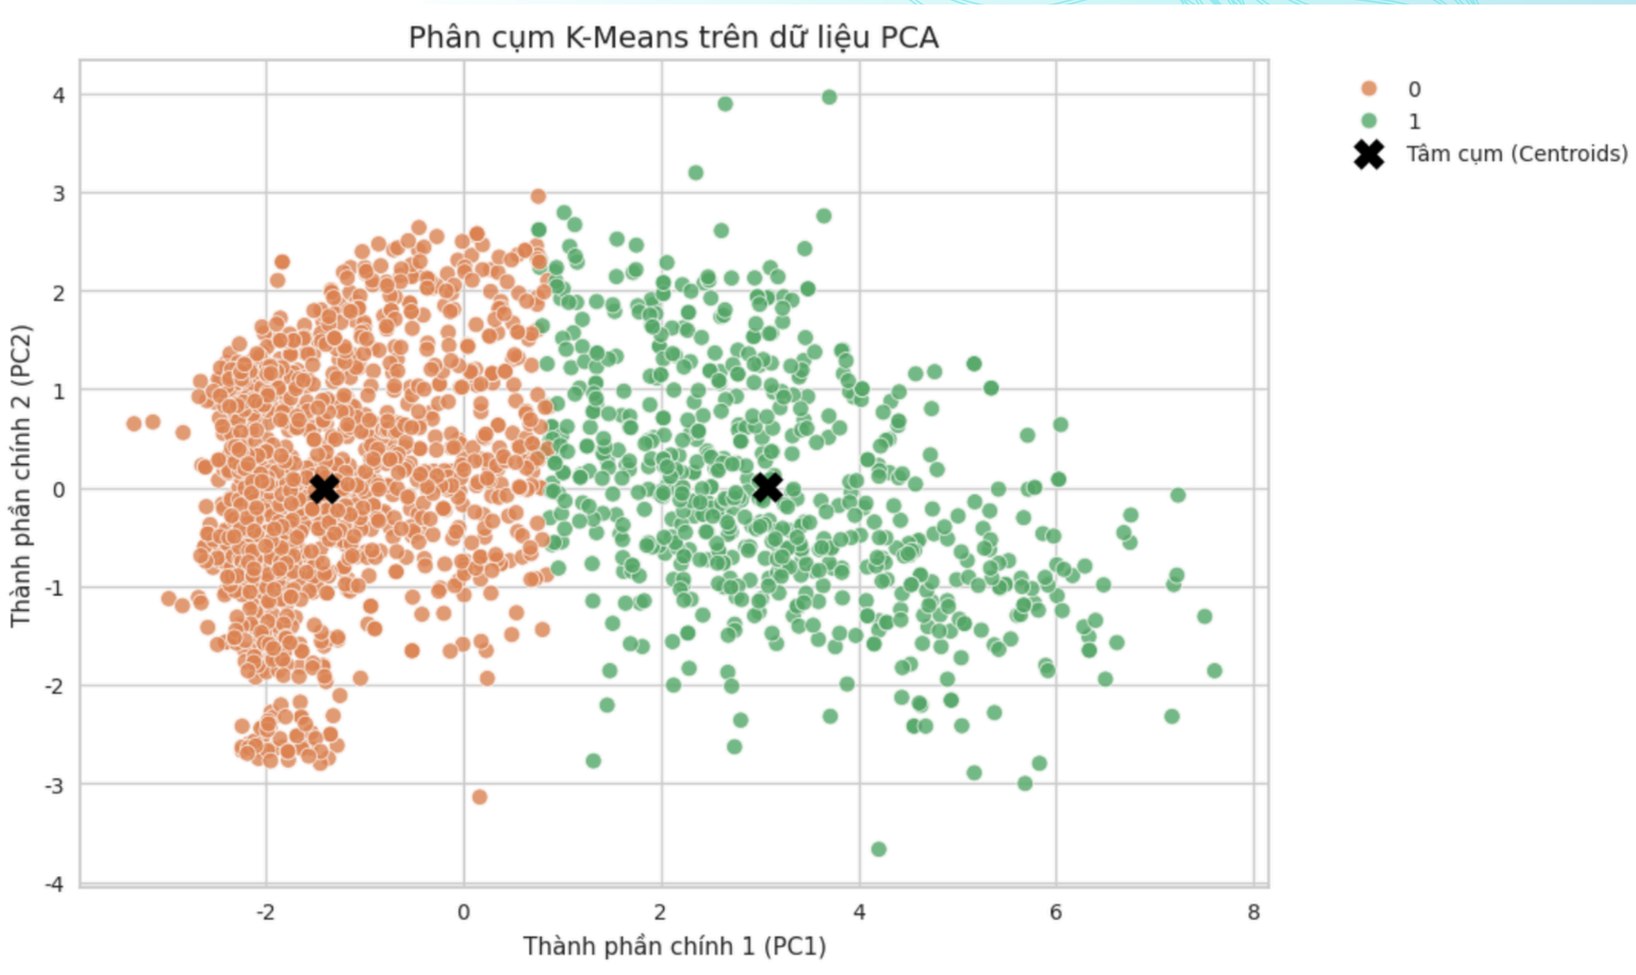

SO SÁNH

Phân cụm KMeans

Phương pháp SILHOUETTE SCORE

- Kết quả: 2 cụm
- Silhouette score: 0.396

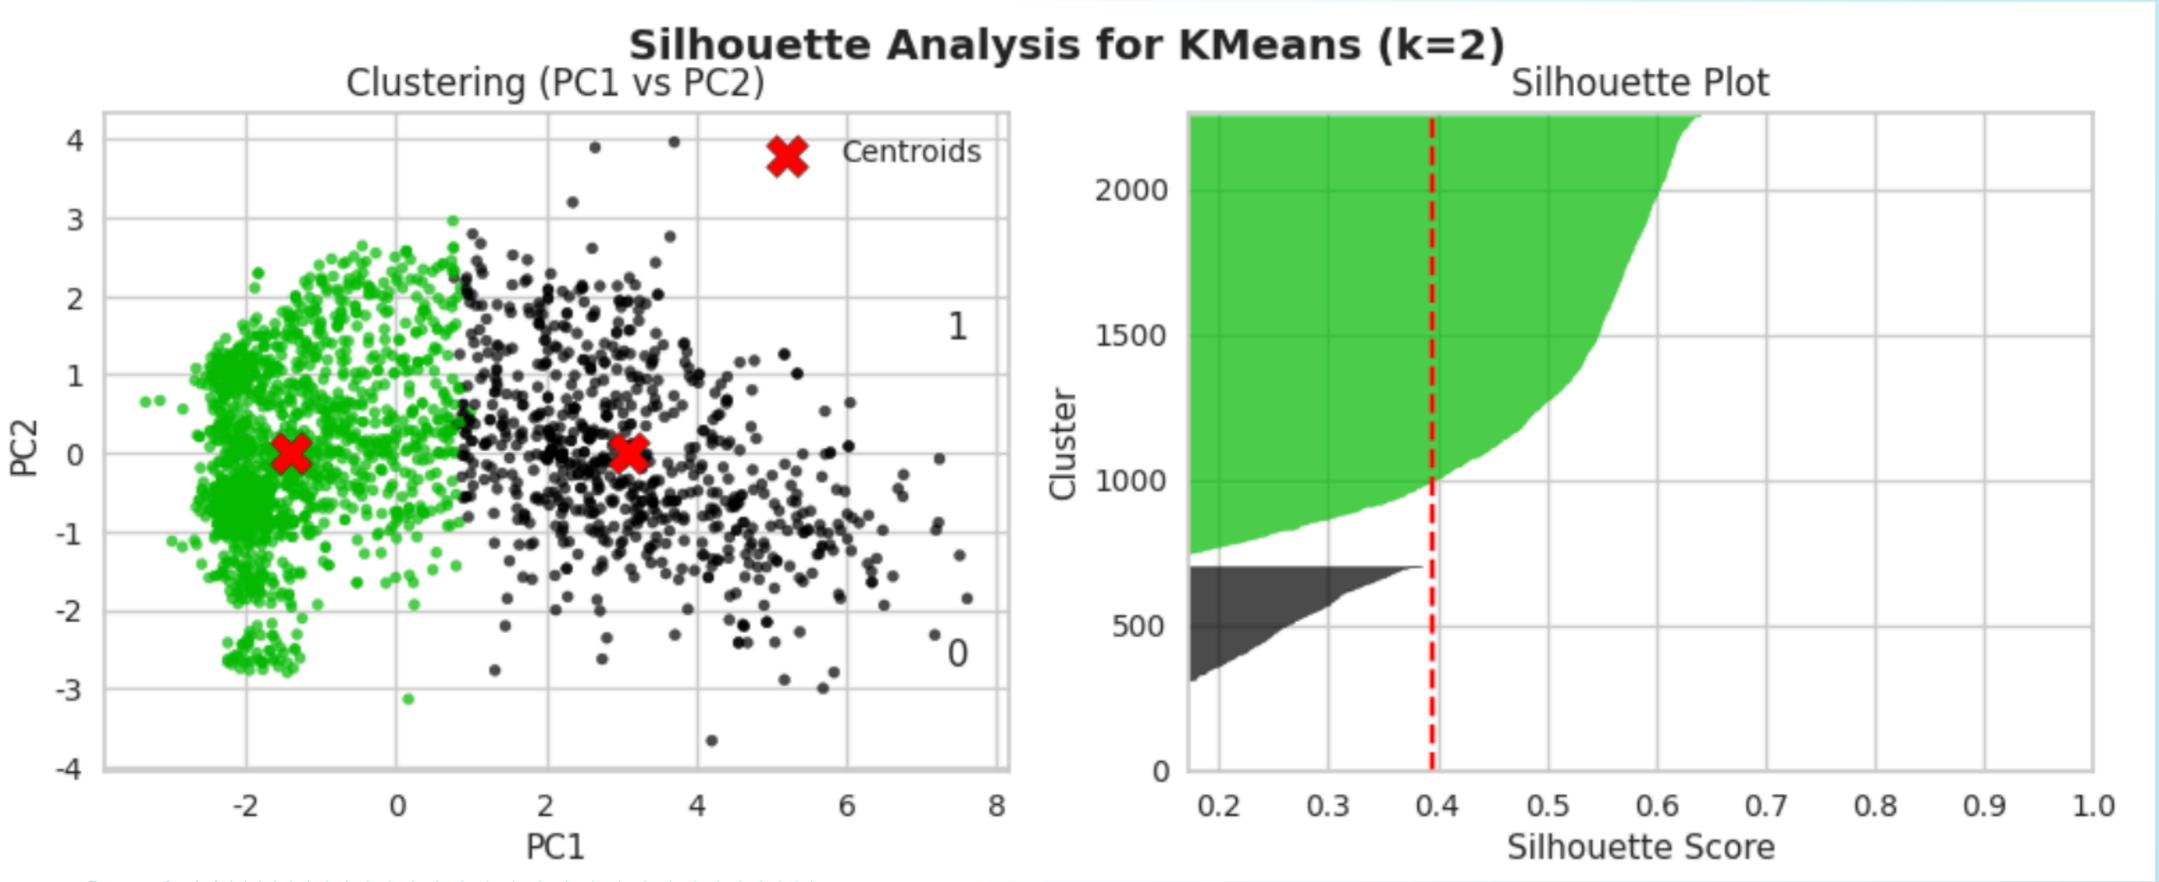

SO SÁNH

Phân cụm HAC

Dendrogram

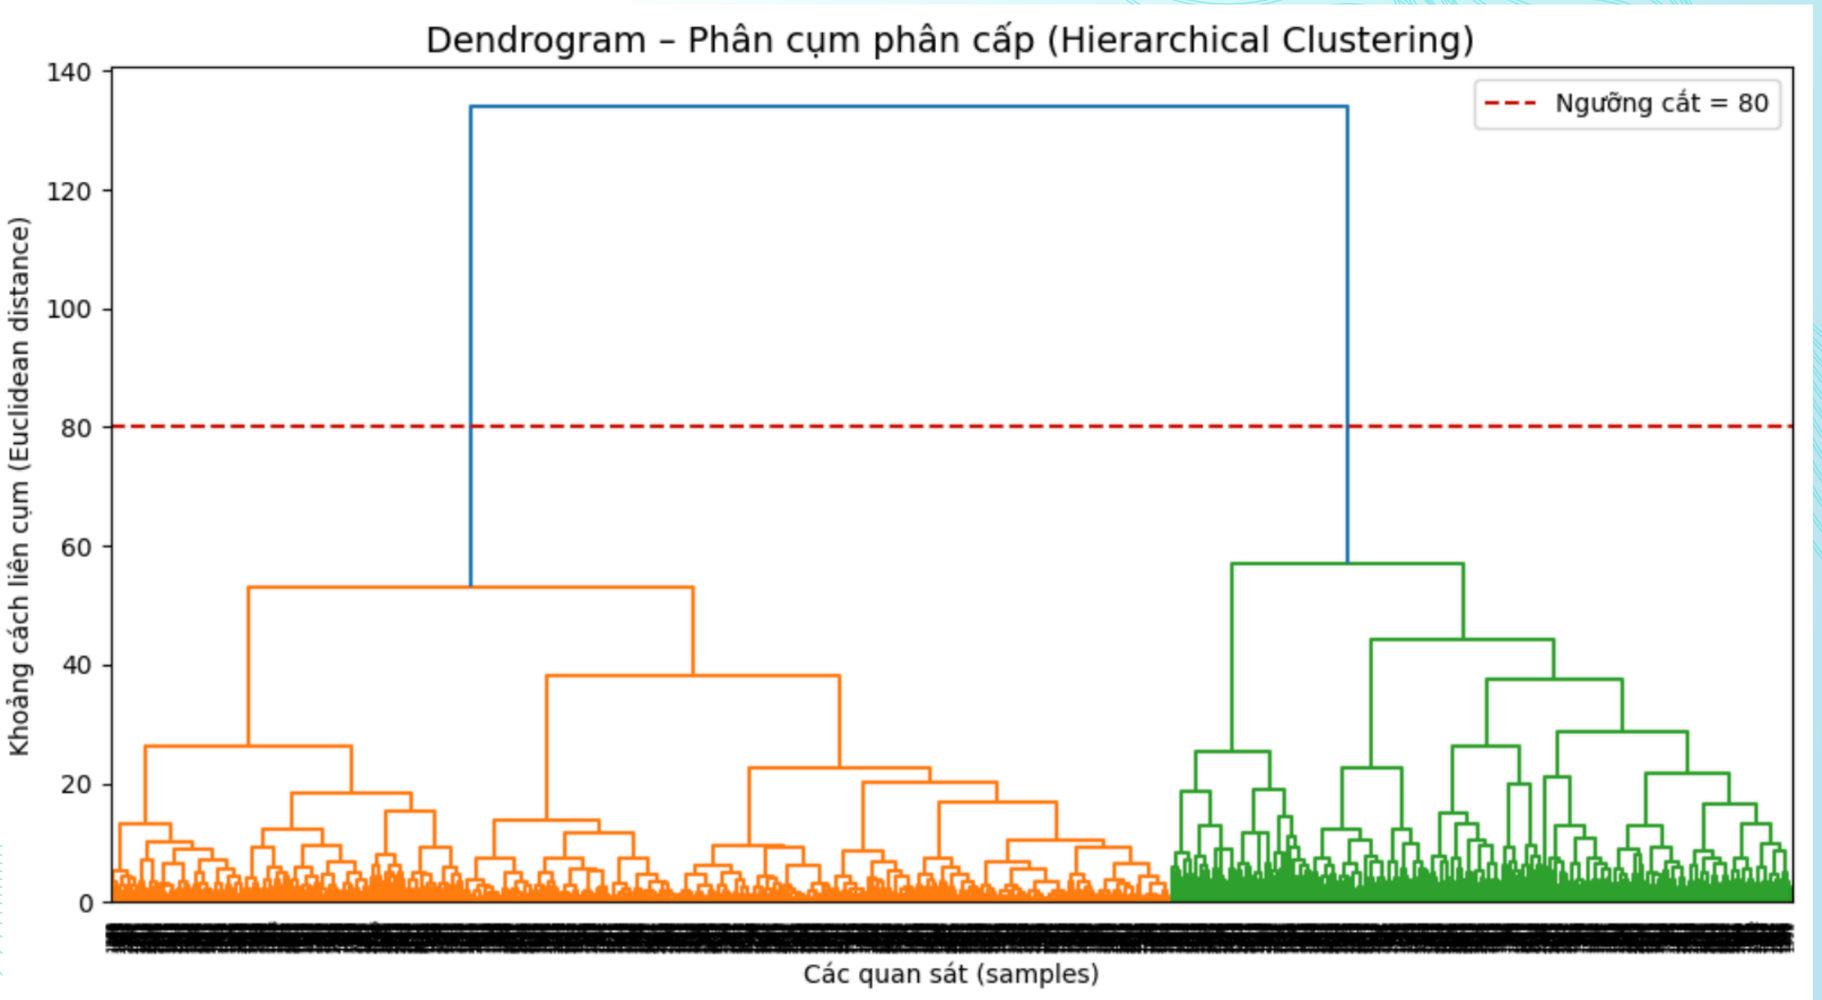

SO SÁNH

Phân cụm HAC

Agglomerative Clustering

- Kết quả: 2 cụm
- Chồng lấn đáng kể giữa hai cụm
- Có xu hướng ưu tiên liên kết các điểm gần nhau về mặt khoảng cách

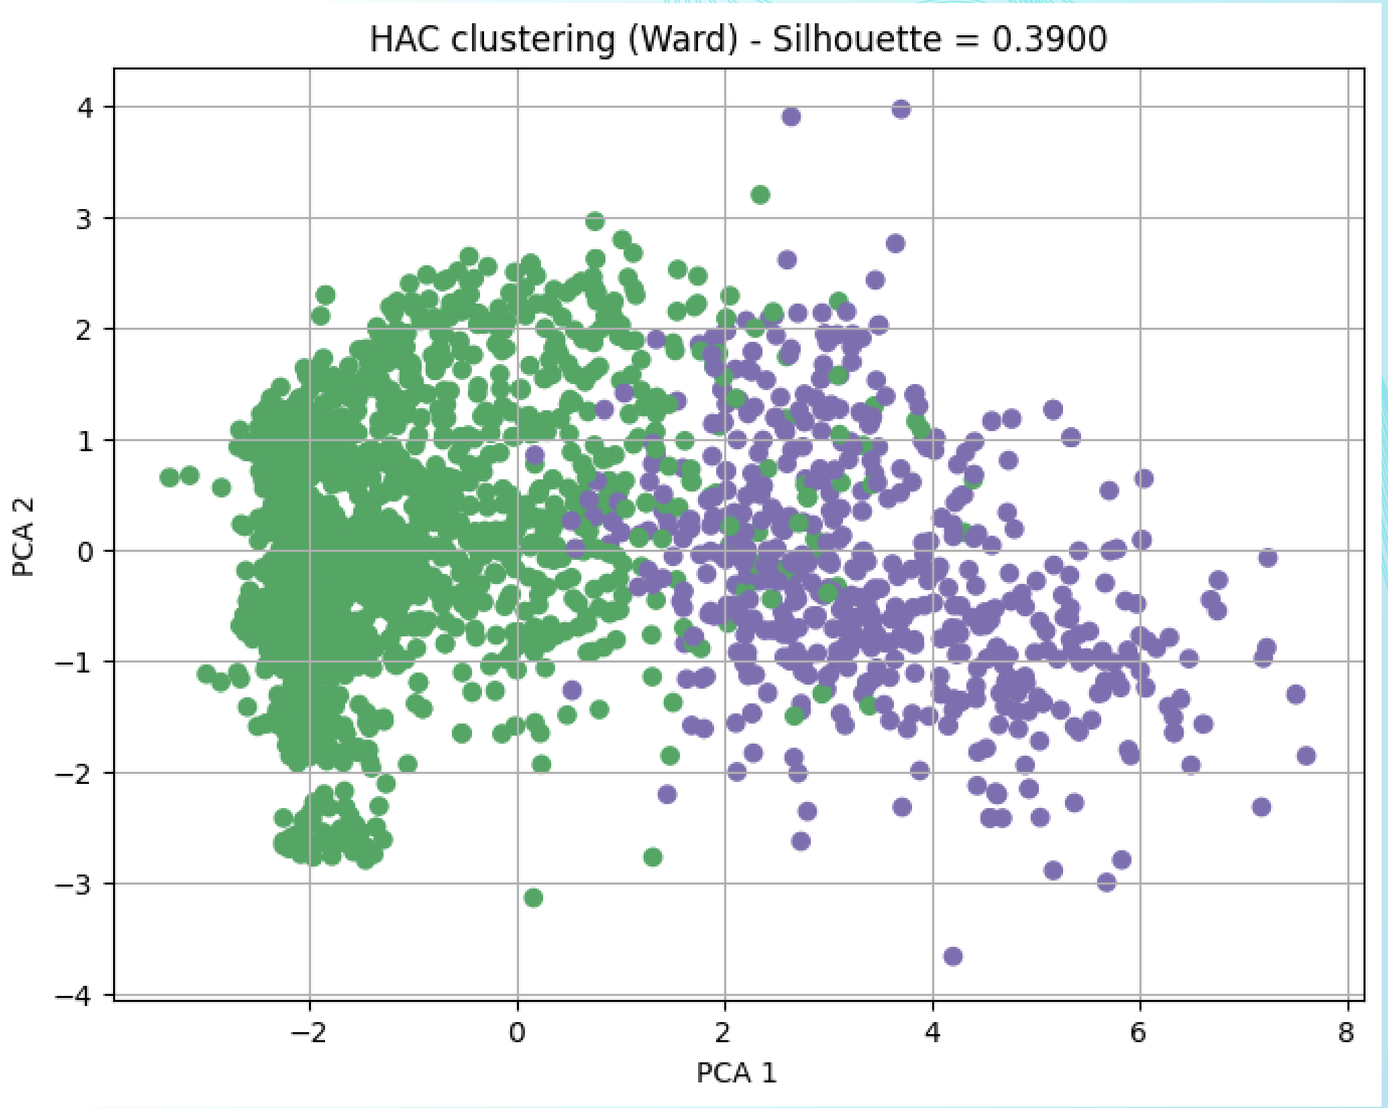

SO SÁNH

Hình dạng các cụm

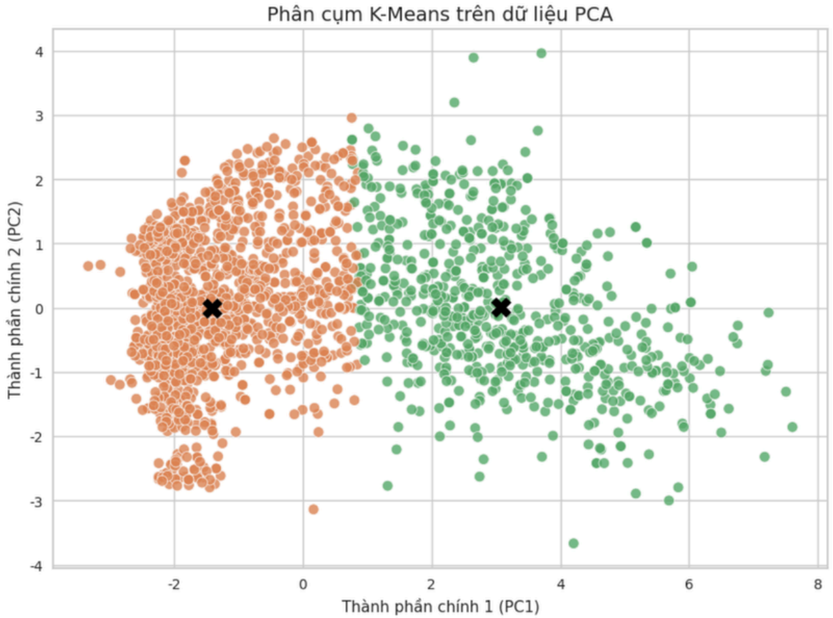

Phân cụm K-means

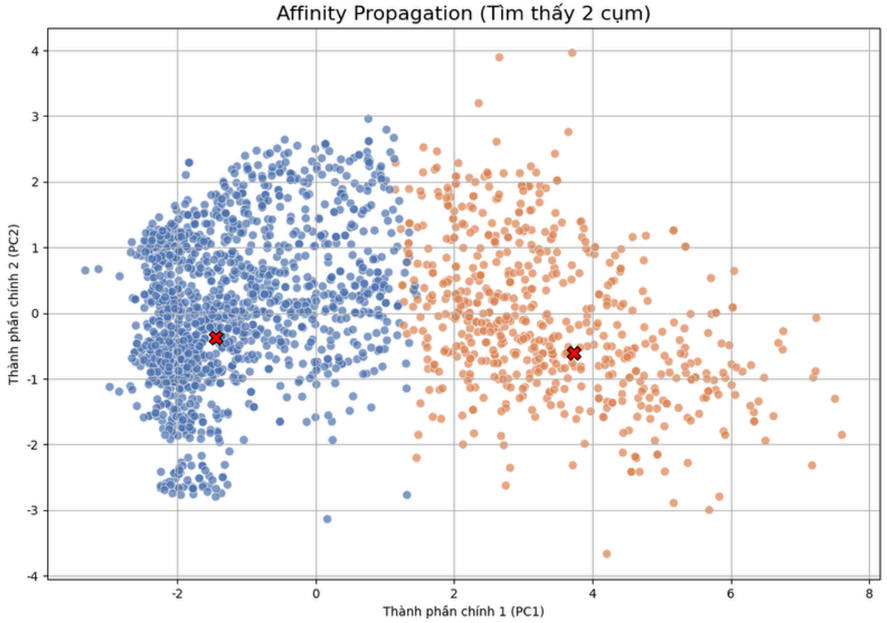

Phân cụm AP

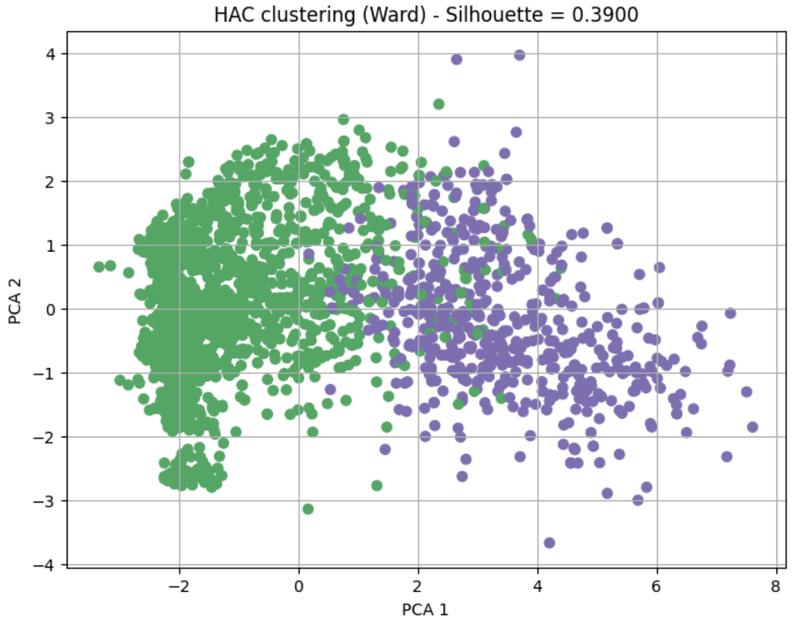

Phân cụm HAC

SO SÁNH

Các chỉ số

- **Silhouette**: mức độ tách biệt và gắn kết giữa các cụm
- **DBI**: mức độ chồng chéo giữa các cụm
- **CHI**: sự cân bằng giữa độ phân tán giữa và trong các cụm

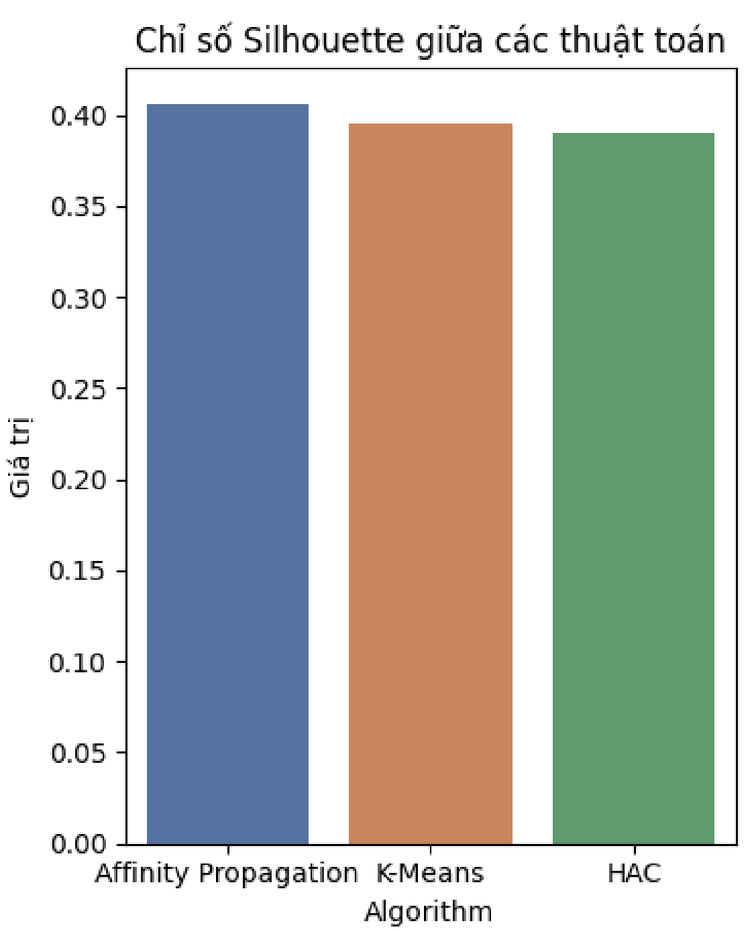

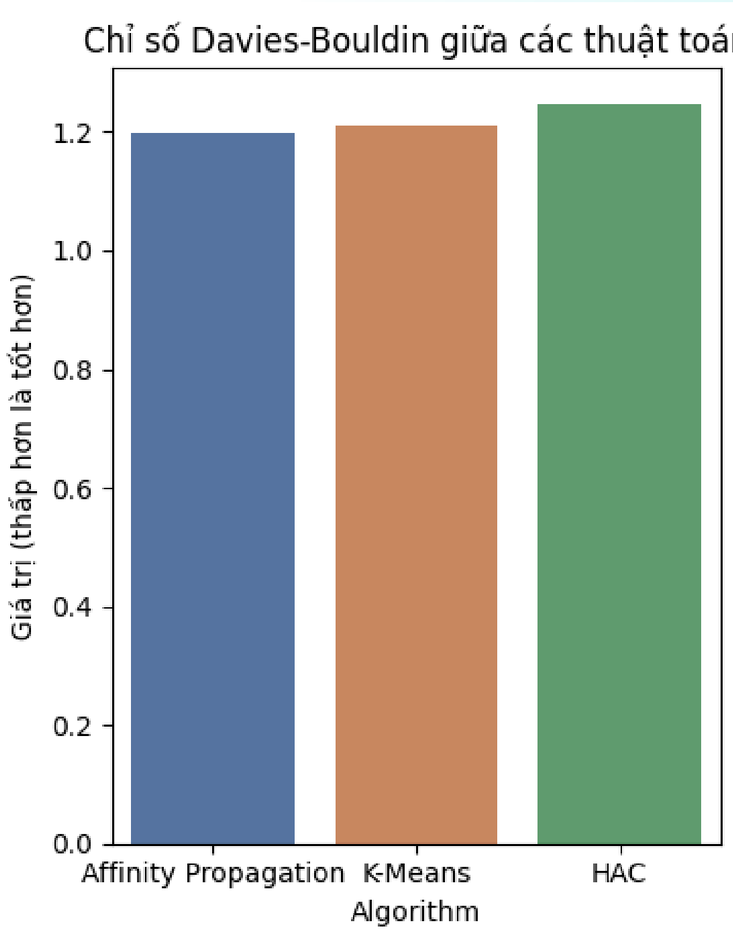

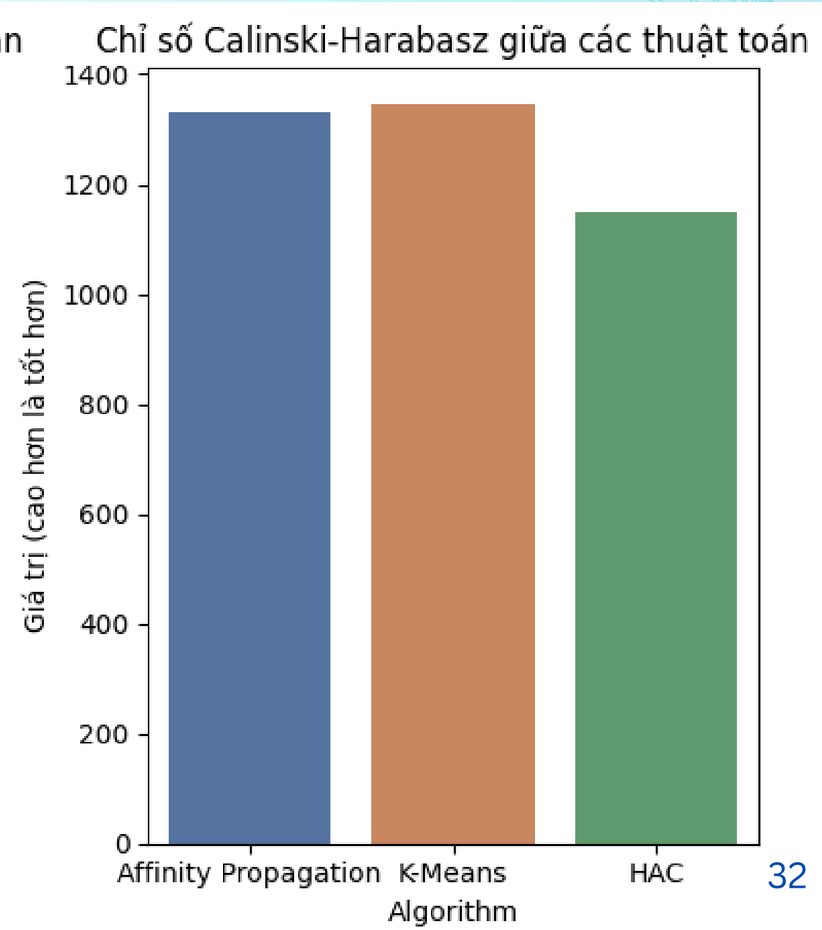

SO SÁNH

Thời gian chạy

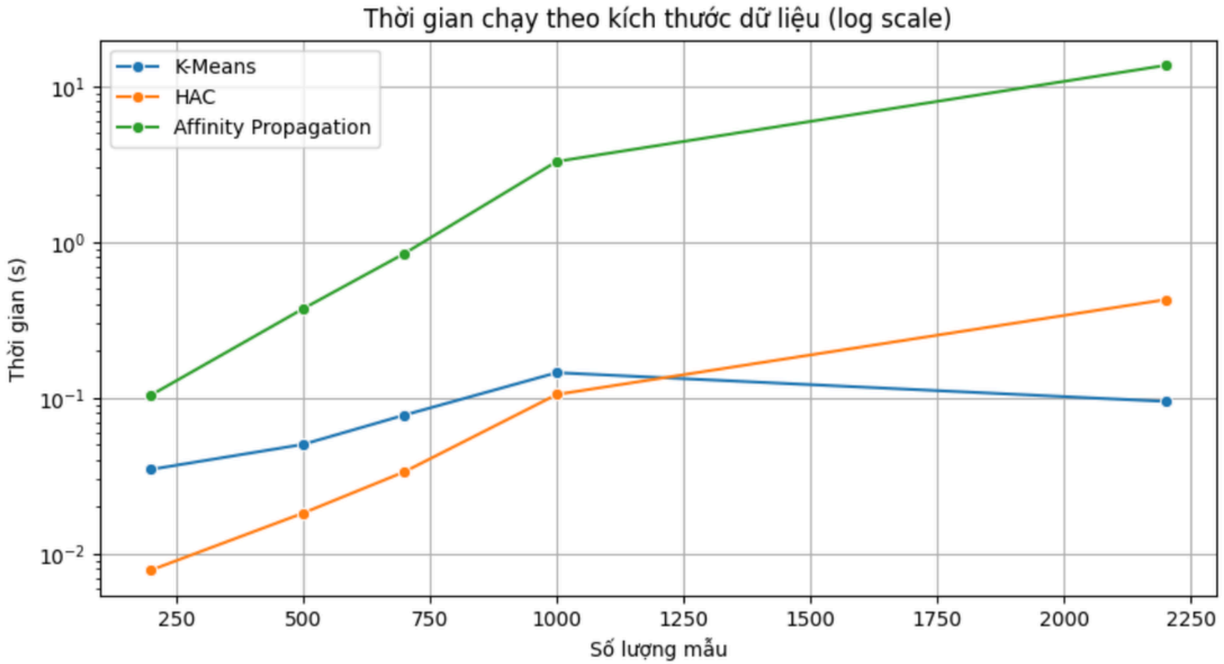

Bộ nhớ

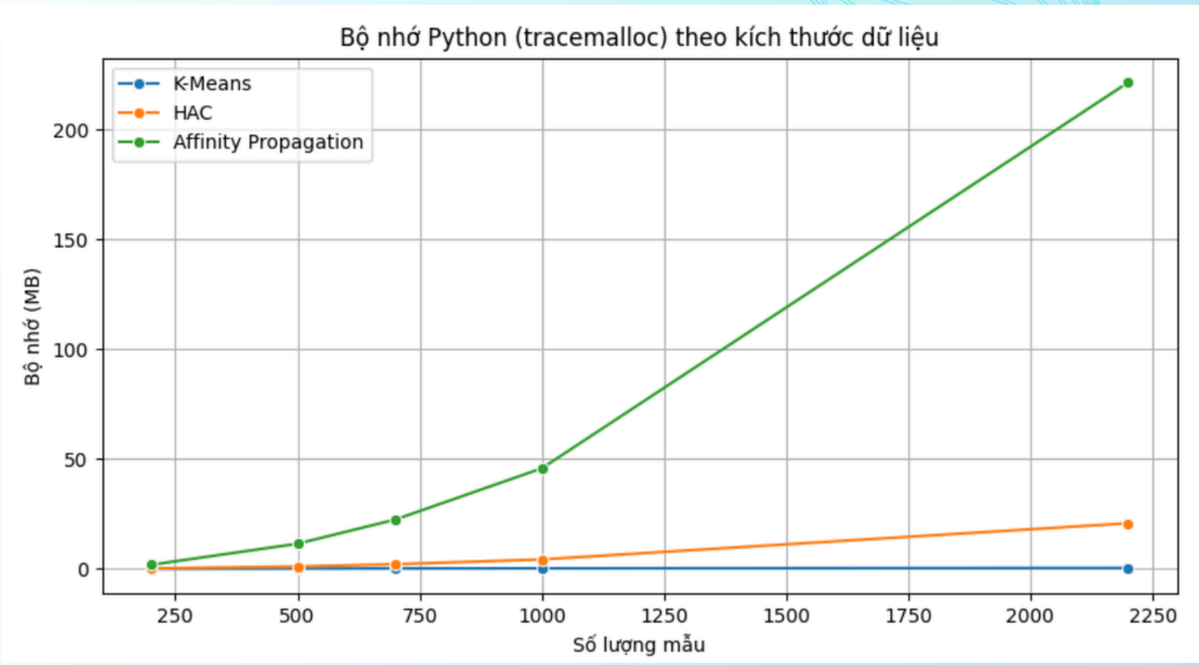

NHẬN XÉT CHI TIẾT

Để làm rõ hơn về đặc điểm của hai cụm sau khi sử dụng thuật toán AP, nhóm quyết định chia các đặc điểm của khách hàng thành ba nhân tố chính

1 **People**

'Year_Birth', 'Education', 'Marital_Status', 'Income', 'children', 'Customer_for', 'Recency'

2 **Product**

'MntWines', 'MntFruits', 'MntMeatProducts', 'MntFishProducts', 'MntSweetProdcts', 'MntGoldProds'

3 **Place**

'NumWebPurchases', 'NumCatalogPurchases', 'NumStorePurchases', 'NumWebVisitsMonth', 'NumDealsPurchases'

NHÓM PEOPLE

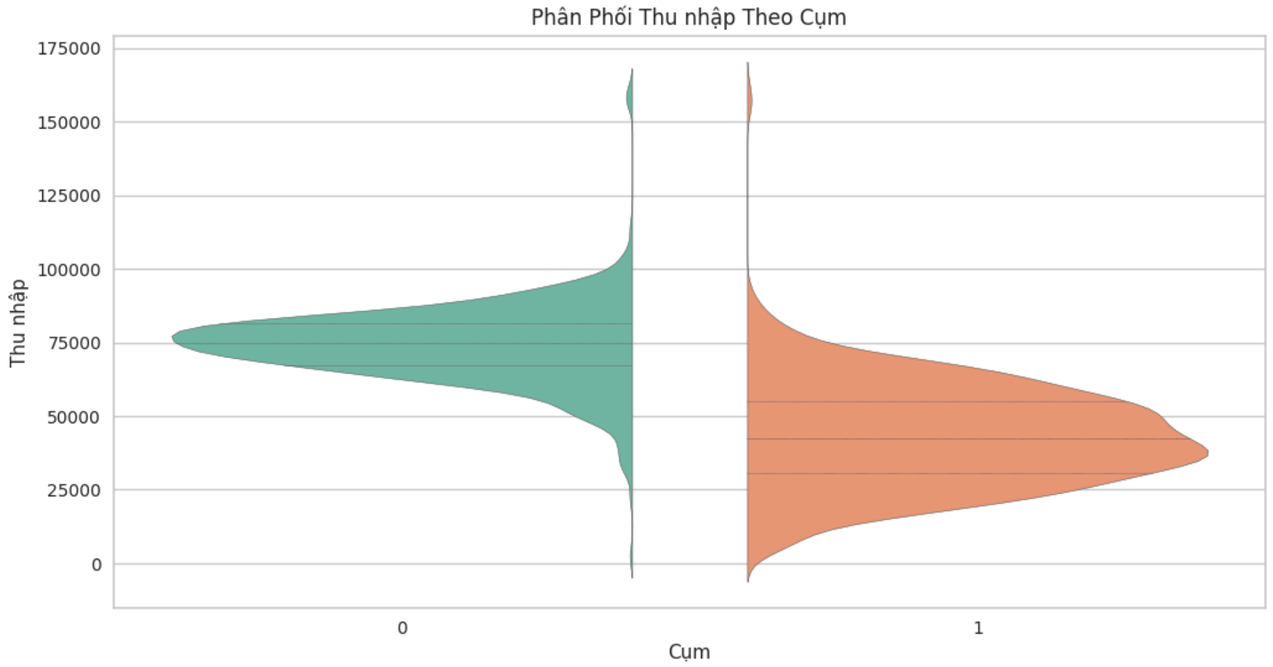

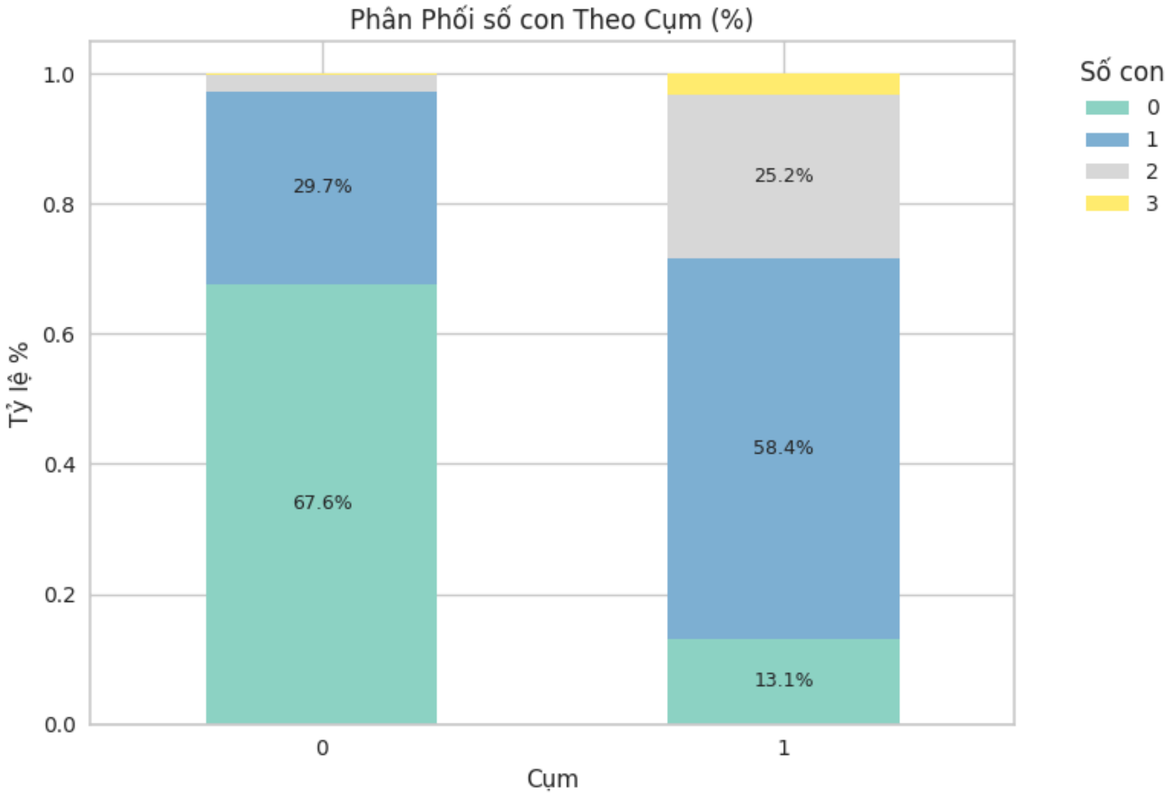

Phân phối thu nhập theo cụm chỉ ra rằng, **khả năng chi trả của Cụm 0 lớn gần gấp đôi Cụm 1**.
Cụm 1 là tập hợp những gia đình có nhiều con hơn.

NHÓM PEOPLE

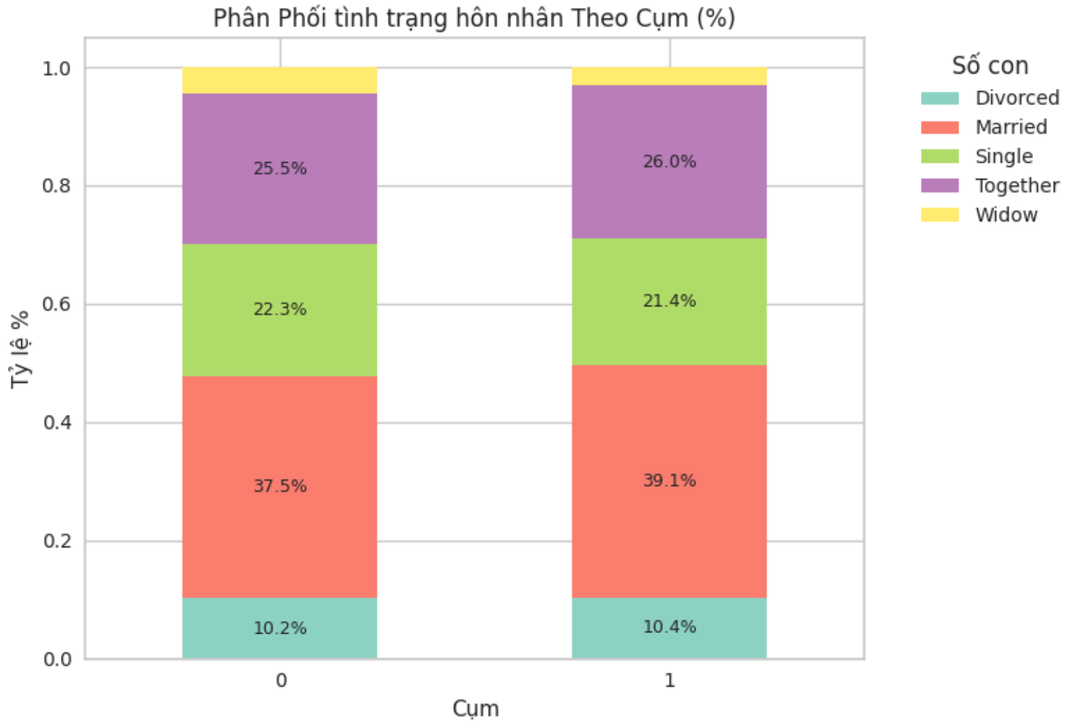

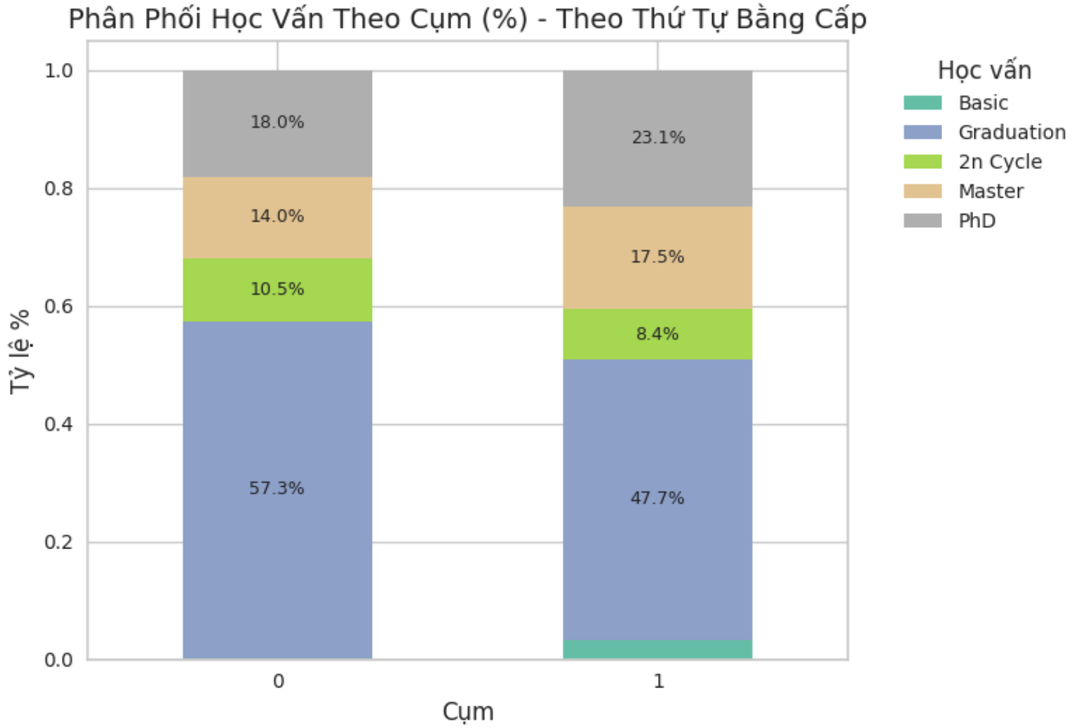

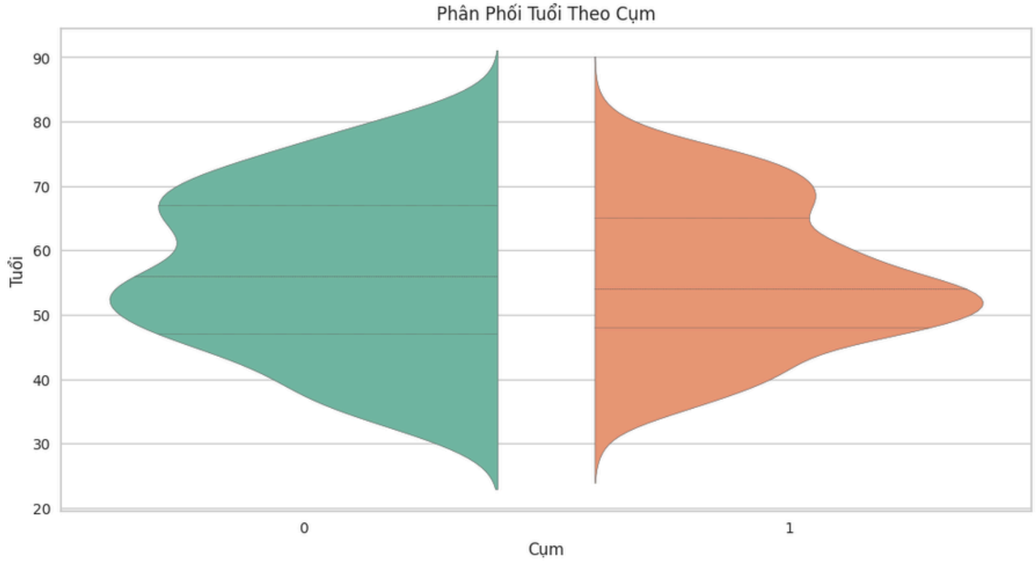

Ngoài ra, các đặc điểm: **tuổi, trình độ học vấn, tình trạng hôn nhân,...** giữa hai cụm tương đối đồng đều, không có khác biệt đáng kể.

NHÓM PRODUCT

Nhóm 0 luôn chi tiêu mạnh tay và nhiều hơn so với nhóm 1 ở tất cả sản phẩm.

- **Nhóm 0:** chi tiêu nhiều với số tiền lớn cho các loại sản phẩm: **rượu, thịt** với đỉnh ở khoảng 250 đến 500. Các sản phẩm còn lại nằm ở mức trung bình đỉnh ở 50 và mở rộng đến gần 200.

- **Nhóm 1:** hầu như **không chi tiêu nhiều** cho hầu hết các loại sản phẩm, có phân phối hẹp và phân bố xung quanh mode(mode nằm gần 0).

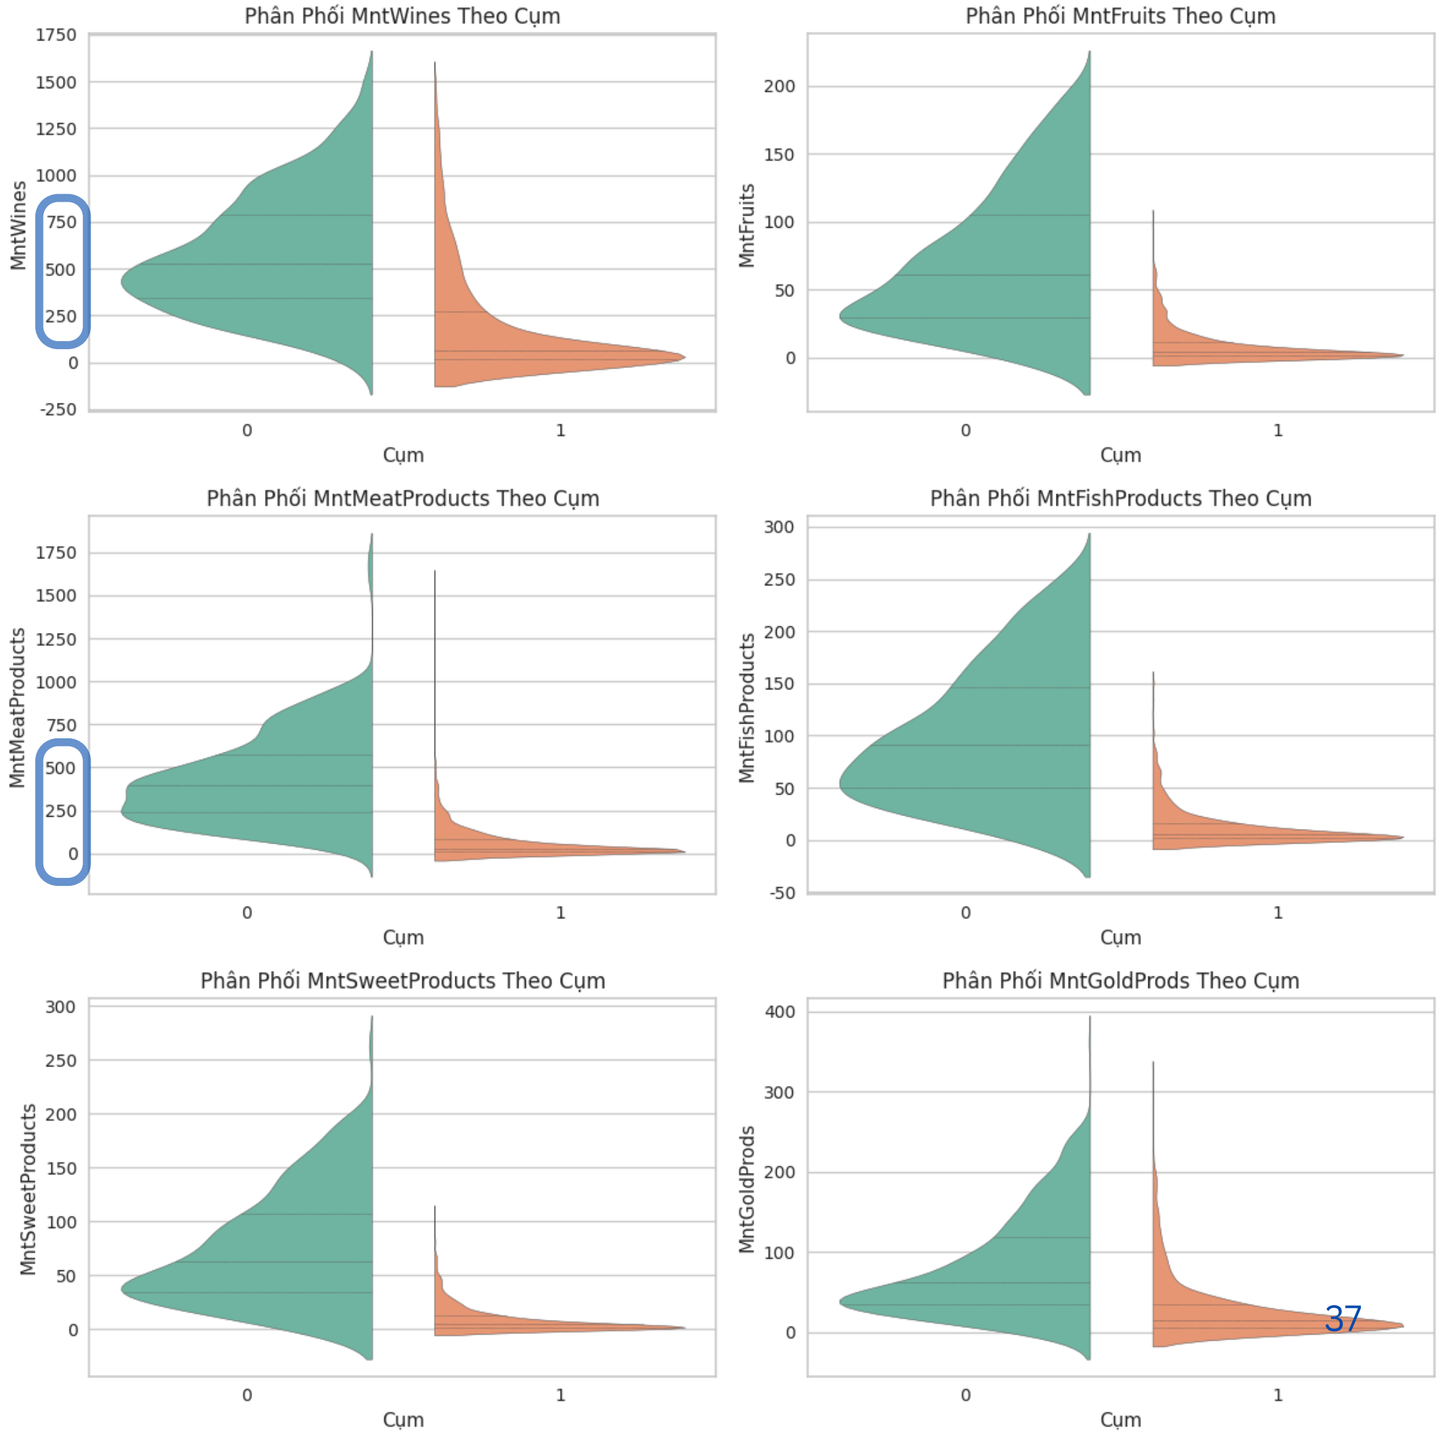

NHÓM PRODUCT

- **Nhóm 0:** Chi tiêu nhiều hơn cho các loại sản phẩm, đạt đỉnh khoảng từ 1000 đến hơn 1500 và chi tiêu có trải về phía hơn 2500.

- **Nhóm 1:** Chi tiêu kiểm soát đỉnh gần với giá trị khoảng 100. Mặc dù có các giá trị trải dài đến 2000 nhưng là rất ít và không đáng kể.

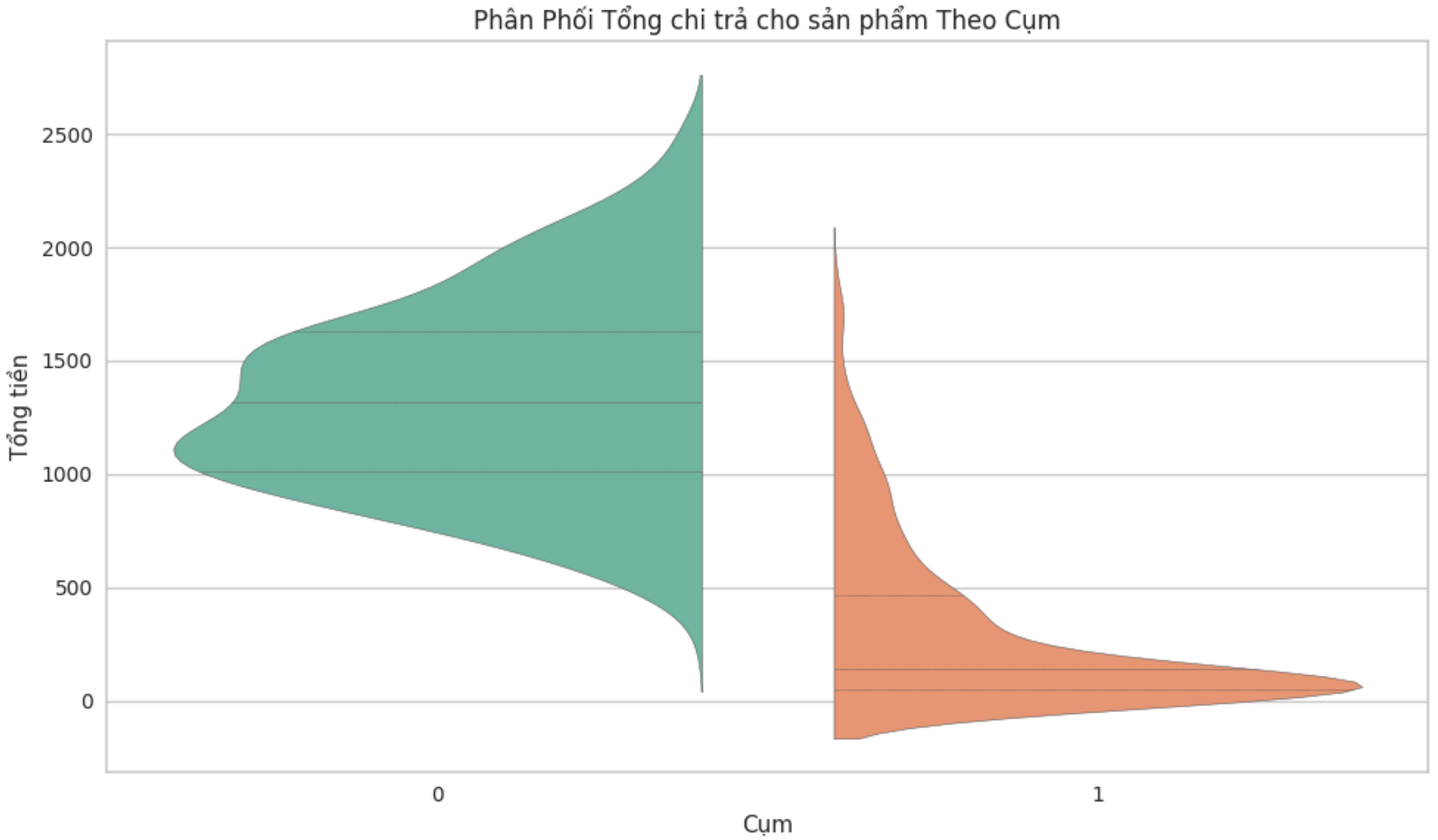

NHÓM PLACE

- **Tại Web (sức mua trung bình)**
- Mặc dù **nhóm 1 truy cập web nhiều hơn** đáng kể so với nhóm 0, nhưng số lần mua trên web của **nhóm 1 lại ít hơn nhóm 0**

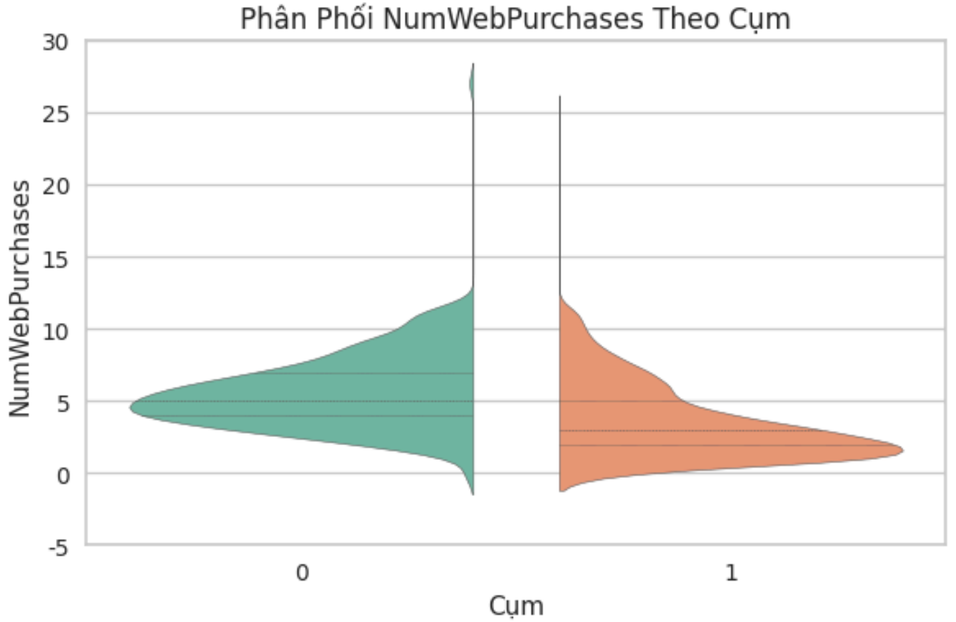

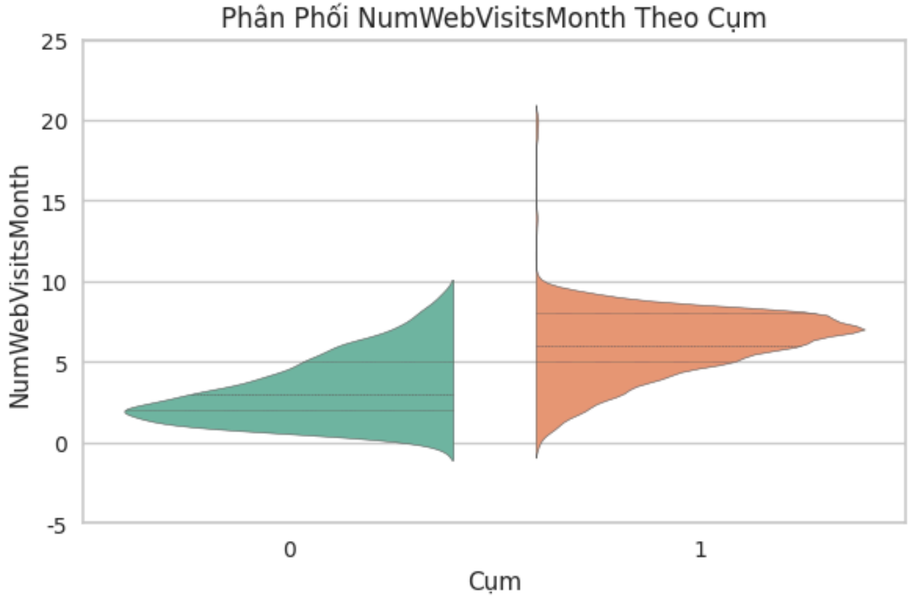

NHÓM PLACE

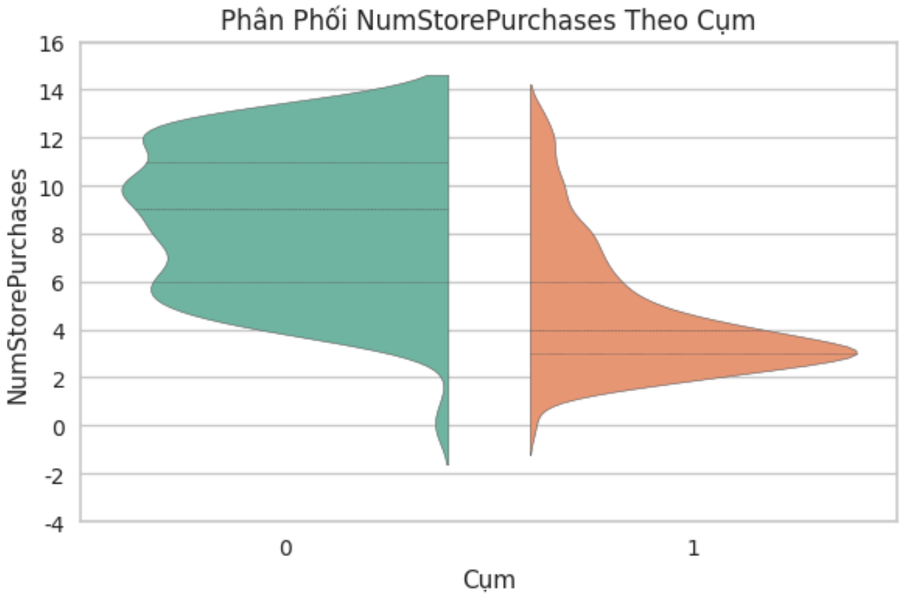
Phân Phối NumStorePurchases Theo Cụm
NumStorePurchases
16
14
12
10
8
6
4
2
0
-2
-4
0
1
Cụm

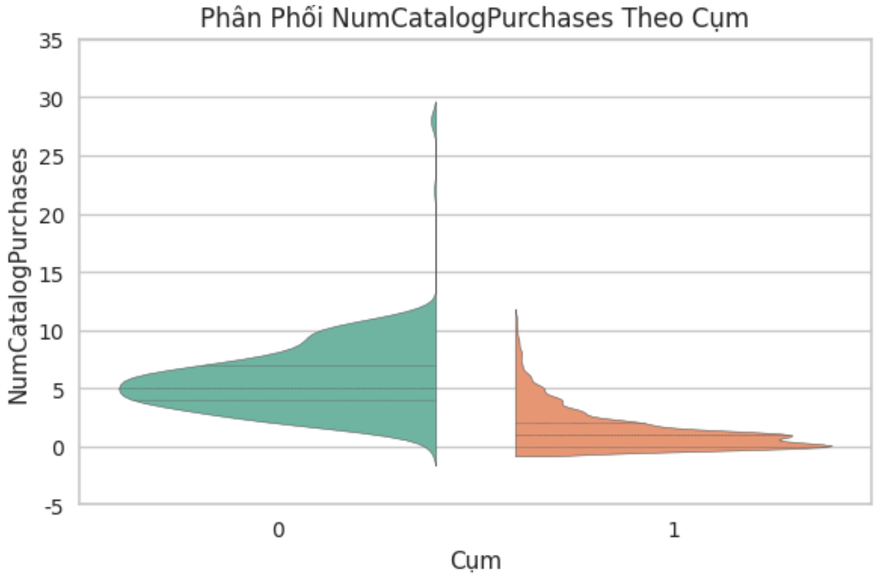
Phân Phối NumCatalogPurchases Theo Cụm
NumCatalogPurchases
35
30
25
20
15
10
5
0
-5
0
1
Cụm

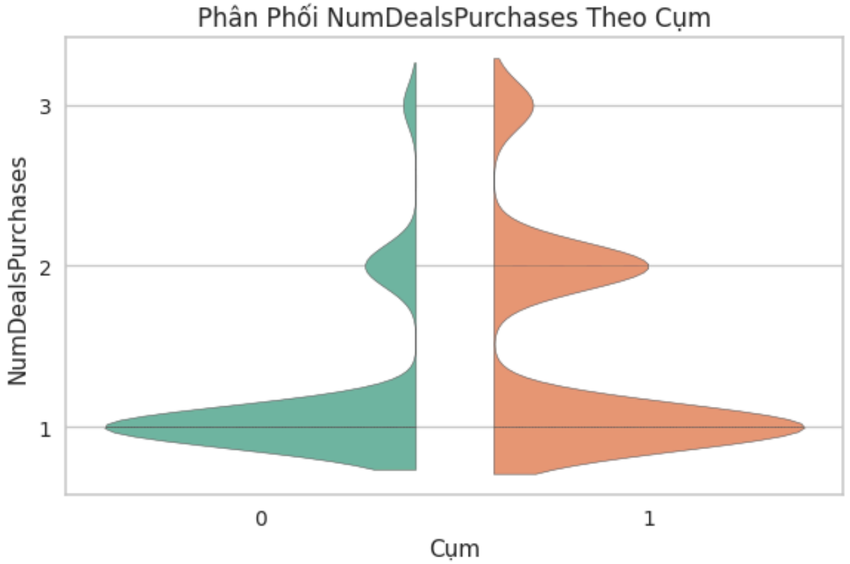
Phân Phối NumDealsPurchases Theo Cụm
NumDealsPurchases
3
2
1
0
1
Cụm

NHÓM PLACE

Nhìn chung **sức mua của Cụm 0 cao hơn Cụm 1 khá nhiều**, điều này có thể giải thích được khi ở mục số tiền chi trả cho sản phẩm thì Cụm 0 cũng cao vượt trội so với Cụm 1

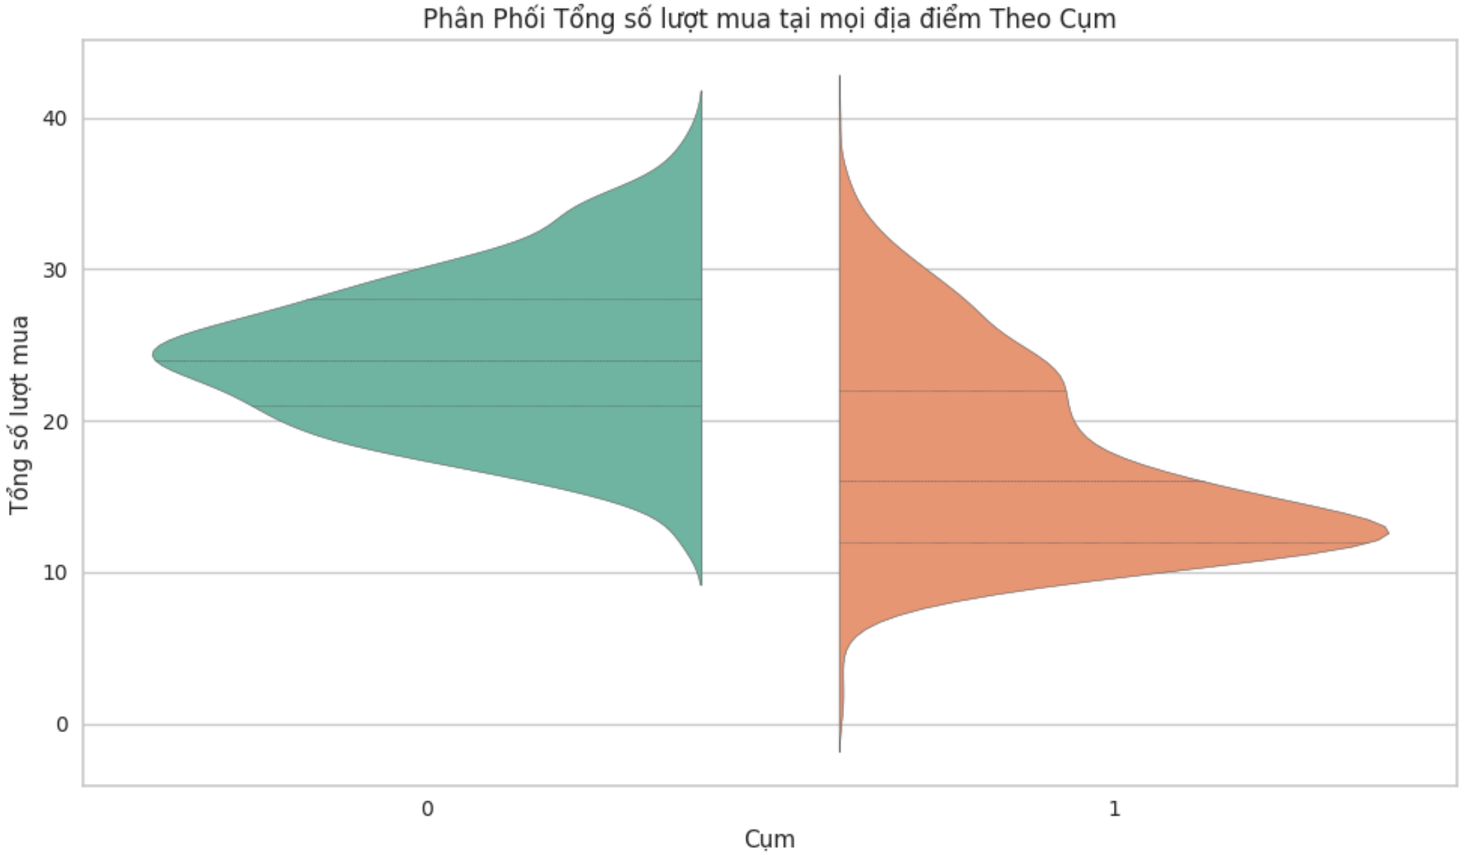

HỒ SƠ PHÂN KHÚC

NHÓM 0		NHÓM 1
627 người		1607 người
Thu nhập cao		Thu nhập trung bình
Nhà ít con		Nhà đông con
Chi tiêu mạnh		Chi tiêu kiểm soát
Số lượt mua trung - cao		Số lượt mua thấp
Ít quan tâm khuyến mãi		Nhạy với giá cả và khuyến mãi

KẾT LUẬN

- Đối với bộ dữ liệu này, kết quả phân cụm theo **AP là tốt nhất.**
- Tuy nhiên, xét về **bộ nhớ** và **tốc độ** thực thi, thuật **AP có nhiều hạn chế** so với **K-means** và **HAC**.
- Do đó, nếu bộ dữ liệu có **nhiều điểm hơn**, việc áp dụng thuật AP cần được cân nhắc kỹ lưỡng trước khi thực hiện để tránh **tràn RAM**, dẫn đến thuật toán không được thực hiện hoàn tất.

CẢM ƠN THẦY VÀ CÁC BẠN ĐÃ LẮNG NGHE